crisp-dm-couriers

July 5, 2024

1 Trabajo Final de Máster

Máster en Data Science For Business

Estudiantes:

- Maria Jesús Quirós
- Jorge Luis Barquero Villagra

Tutor: Ramón Alberto Carrasco

2 CRISP-DM

3 Requisitos previos:

Para ejecutar el siguiente notebook se debe tener un ambiente de Python con las siguientes librerías instaladas.

Versión de Python 3.8.xx

- mysql-connector-python 8.4.0
- plotly 5.9.0
- mlxtend 0.23.1
- networkx 3.1
- fbprophet 1.1.5
- openpyxl 3.0.10
- nbformat 5.9.2

[ ]:
```
# %pip install mysql-connector-python
# %pip install plotly
# %pip install mlxtend
# %pip install networkx
# %pip install fbprophet
# %pip install openpyxl
# %pip install nbformat
```

[ ]:
```
# Imports para ejecución del notebook
import pandas as pd
import os as os
import matplotlib.pyplot as plt
```

```
import plotly.express as px
import numpy as np
import sqlite3
import plotly.io as pio
from mlxtend.frequent_patterns import association_rules
from mlxtend.frequent_patterns import apriori
from prophet import Prophet

# Variable global para administrar el directorio actual
parent_dir = os.path.dirname(os.getcwd())

# Configuración para los renders de plotly
pio.renderers.default = 'notebook'

# Ubicación de base de datos
database_name = '/data/database/tfm_couriers.db'

# Funciones reutilizables
def SalvarEnBD(table_name, data):
    conn = sqlite3.connect(parent_dir + database_name)
    # Convierte el DataFrame a una tabla SQL
    data.to_sql(table_name , conn, if_exists='replace', index=False)
```

```
/Users/jorgebarquero/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-
packages/holidays/__init__.py:32: FutureIncompatibilityWarning:

This is a future version incompatibility warning from Python Holidays library
v0.50
to inform you about an upcoming change in our API versioning strategy that may
affect your
project's dependencies. Starting from version 1.0 onwards, we will be following
a loose form of
Semantic Versioning (SemVer) to provide clearer communication regarding any
potential breaking
changes.

This means that while we strive to maintain backward compatibility, there might
be occasional
updates that introduce breaking changes to our API. To ensure the stability of
your projects,
we highly recommend pinning the version of our API that you rely on. You can pin
your current
holidays v0.x dependency (e.g., holidays==0.50) or limit it (e.g., holidays<1.0)
in order to
avoid potentially unwanted upgrade to the version 1.0 when it's released (ETA
2024Q4 - 2025Q1).

If you have any questions or concerns regarding this change, please don't
```

```
hesitate to reach out
to us via https://github.com/vacanza/python-holidays/discussions/1800.

  warnings.warn(
/Users/jorgebarquero/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-
packages/tqdm/auto.py:21: TqdmWarning: IProgress not found. Please update
jupyter and ipywidgets. See
https://ipywidgets.readthedocs.io/en/stable/user_install.html
  from .autonotebook import tqdm as notebook_tqdm
```

4 Business Understanding - listo

Un courier es una empresa o servicio especializado en la entrega rápida y eficiente de paquetes, documentos y otros tipos de envíos. A diferencia de los servicios postales tradicionales, los couriers suelen ofrecer una mayor velocidad, seguridad y confiabilidad en la entrega de sus envíos. Suelen caracterizarse porque sus servicios incluyen:

- Rapidez: Algunas empresas couriers pueden hacer entregas en el mismo día, al día siguiente o en un plazo muy corto, dependiendo de la urgencia del envío.
- Seguimiento: Los envíos por courier generalmente pueden ser rastreados en tiempo real, proporcionando información precisa sobre el estado y la ubicación del paquete.
- Seguridad: Los couriers a menudo ofrecen un manejo más cuidadoso de los envíos, con seguros y opciones de firma al recibir el paquete.
- Flexibilidad: Ofrecen una amplia gama de servicios, desde entregas locales y nacionales hasta envíos internacionales, adaptándose a las necesidades específicas de sus clientes.
- Servicio al cliente: Proporcionan atención personalizada y soluciones específicas para problemas o necesidades de envío.

Los couriers son utilizados tanto por particulares como por empresas que necesitan enviar documentos importantes, productos comprados en línea, muestras comerciales, y otros tipos de paquetes que requieren una entrega rápida y segura.

La empresa ExpediteX es una empresa dedicada a prestación de servicios logísticos de Courier y mensajería, que cuenta con 25 años de experiencia en el mercado. Sus servicios van desde la importación de productos en la modalidad de carga y paqueteo, distribución local y nacional a domicilio, hasta la asesoría para la importación y exportación, casillero internacional y asesoría de compras internacionales.

Por otro lado, SwiftShip cuenta con experiencia de 19 años en el manejo y traslado de paquetes y encomiendas, se caracterizan por trabajar directamente, sea, desde el recibimiento hasta la entrega de las mercancías es manejada por la empresa directamente (sin intermediarios).

Adicionalmente cuentan con 207 sucursales y/o puntos de recepción a nivel internacional en 50 países diferentes, entre ellos Estados Unidos, Canadá, Panamá, República Dominicana, Guatemala, Venezuela, Argentina, Brasil, Chile, Colombia, Ecuador, Perú, Uruguay, España, Italia, Portugal, Alemania y el resto de la Comunidad Europea.

Ambas empresas operan en un mercado muy competitivo, donde la eficiencia en la entrega, la cobertura geográfica y la calidad del servicio al cliente son factores clave para su éxito. Estas empresas ofrecen una variedad de servicios, que van desde la entrega de paquetes locales hasta

el envío internacional, adaptándose a las necesidades de diferentes segmentos del mercado, como particulares y empresas.

La integración de tecnologías avanzadas, como el rastreo en tiempo real y la gestión automatizada de inventarios y compras juega un papel crucial en la optimización de los procesos logísticos, con lo que la incorporación de toma de la decisiones basadas en datos, tiene gran importancia en las empresas de courier, pues es crucial para optimizar sus operaciones, mejorar la satisfacción del cliente y aumentar la eficiencia en el manejo de envíos.

4.1 Objetivo General - listo

Desarrollar mediante la metodología CRISP-DM un análisis de datos sobre los procesos de importación de las empresas SwiftShip y ExpediteX de courier en Costa Rica durante el período 2021-2023, para la optimización de sus operaciones y mejora de la toma de decisiones estratégicas. Utilizando técnicas avanzadas de análisis de datos y las herramientas disponibles, se espera obtener al menos cinco recomendaciones concretas y presentar los hallazgos en un informe detallado en el plazo de cuatro meses.

4.2 Objetivos Específicos - listo

- Implementar un análisis de cesta (basket analysis) utilizando algoritmos de asociación para la identificación de los patrones más relevantes de compra y relaciones entre los productos adquiridos por los importadores que han utilizado los servicios de las empresas SwiftShip y ExpediteX de courier en Costa Rica. Utilizando los datos de transacciones de los últimos tres años, se espera la mejora en las estrategias de marketing y optimización del servicio. El análisis se lleva a cabo y los resultados se presentan en un informe detallado en un plazo de tres meses.
- Realizar un análisis de tendencias de las mercancías importadas utilizando técnicas de análisis de series temporales, para la identificación de patrones significativos y cambios importantes en la demanda de diferentes tipos de mercancías a lo largo del tiempo. Esto permitirá la anticipación de las necesidades logísticas y ajustes de estrategias de importación para la mejora de la eficiencia operativa. Dicho análisis se completará en un plazo de seis meses.
- Diseñar un conjunto de tres variables ingenieriles específicas para la implementación en las empresas SwiftShip y ExpediteX, para la optimización de los procesos de importación bajo la modalidad courier. Utilizando técnicas de análisis de datos y conocimientos de la industria, se espera la mejora de la eficiencia y efectividad de dichos procesos. Este diseño y la implementación de un plan piloto se completarán en un plazo de cinco meses.

4.3 Definiciones - listo

- **Aduana:** Unidad técnico-administrativa encargada de las gestiones aduaneras y del control de las entradas, la permanencia y la salida de las mercancías objeto del comercio internacional (Art. 13 LGA).
- **Agente aduanero:** Profesional auxiliar de la función pública aduanera autorizado por la DGA para actuar, en su carácter de persona natural en la presentación habitual de servicios a terceros, en los trámites, los regímenes y las operaciones aduaneras. (Art. 33, LGA)

- **Auxiliar de la Función Pública:** Personas físicas o jurídicas, públicas o privadas, que participen habitualmente ante el Servicio Nacional de Aduanas (SNA), en nombre propio o de terceros. (Art. 28 LGA).
- **Bultos:** Unidad utilizada para contener mercancías. Puede consistir en cajas, sacas, fardos, cilindros y demás formas de presentación de las mercancías, según su naturaleza (Ministerio de Hacienda, 2021).
- **Código Sistema Arancelario Centroamericano (SAC):** El Arancel Centroamericano de Importación está constituido por el Sistema Arancelario Centroamericano (SAC) y los correspondientes Derechos Arancelarios a la Importación (DAI). El código numérico del SAC está representado por diez dígitos que identifican: los dos primeros, al capítulo; los dos siguientes, a la partida; el tercer par, a la subpartida; y los cuatro últimos, a los incisos arancelarios. La identificación de las mercancías se hará siempre con los diez dígitos de dicho código numérico. (Estrategia Aduanera, s.f.)
- **Código Sistema Armonizado (SA):** El Sistema Armonizado (SA) es un código de clasificación de mercancías creado por la Organización Mundial de Aduanas (OMA) y está compuesto por 6 dígitos con aceptación en todo el mundo. Sirve para llevar un control en las mercancías de exportación e importación en cuanto a los impuestos internos, monitoreo de bienes, origen y materia constitutiva.
- **Declarante:** El importador o consignatario, en el caso de la importación de mercancías.
- **Depositario Aduanero:** Persona física o jurídica, pública o privada, auxiliar de la función pública aduanera autorizadas mediante concesión por la DGA, que custodian y conservan temporalmente y con suspensión del pago de tributos, mercancías objeto de comercio exterior, bajo la supervisión y el control de la autoridad aduanera. (Ministerio de Hacienda, 2021).
- **Derechos Arancelarios a la Importación (DAI):** Derechos Arancelarios a la Importación que son un porcentaje estipulado por tipo de mercancías y se calcula sobre el Valor Aduanero.
- **Descripción o designación de la mercancía:** Precisa identificación de las características de ésta, sea de manera concreta, detallada, que singulariza de tal forma el objeto a clasificar que no deja duda alguna sobre su tipificación. (Quirós, 2024).
- **DUA:** Documento Único Aduanero, declaración realizada mediante transmisión electrónica de datos, mediante la cual se indica el régimen aduanero y la modalidad que deberá aplicarse a las mercancías (Ministerio de Hacienda, 2021).
- **Empresa de entrega rápida (EER):** Personas físicas o jurídicas legalmente establecidas, autorizadas y registradas ante la DGA, cuyo giro o actividad principal es la prestación de servicios de transporte internacional expreso a terceros, de correspondencia, documentos y envíos de mercancías bajo la modalidad de entrega rápida. (Ministerio de Hacienda, 2021).
- **Envíos de entrega rápida:** Documentos y mercancías transportadas bajo sistemas de entrega rápida o courier, consignadas a terceros. (Ministerio de Hacienda, 2021).
- **Factura Comercial:** Documento expedido conforme a los usos y las costumbres comerciales, justificativo de un contrato de compraventa de mercancías o servicios extendido por el vendedor a nombre y cargo del comprador.
- **Fecha:** Fecha en que fue aceptado el DUA por el Sistema de Tecnología de Información para el Control Aduanero (TICA) de Costa Rica.

- **Flete:** Monto de flete desde el origen, o sea desde el momento en que se elabora el conocimiento de embarque original y se inicia el servicio de transporte hasta el puerto o lugar de importación. (Ministerio de Hacienda, 2021).
- **Identificación (ID) Agente:** Cédula de identidad física u jurídica del Agente Aduanero.
- **Identificación (ID) Declarante:** En el caso que nos ataque, el número de identificación de la empresa declarante ante el Ministerio de Hacienda.
- **Identificación (ID) Localización:** Número de identificación de la empresa donde está localizada la mercancía, en el caso de envíos de courier, suele referirse al Depositario Aduanero o Almacén fiscal.
- **Importador:** Empresario o empresa que se dedica a comprar productos a clientes del exterior para luego venderlos en el mercado local o para consumo o uso propio.
- **Impuesto sobre el Valor Agregado (IVA):** Según el artículo 1 de la Ley 9635, el impuesto sobre el valor agregado se establece en la venta de bienes y en la prestación de servicios, independientemente del medio por el que sean prestados, realizados en el territorio en Costa Rica.
- **Impuestos Selectivo de Consumo (SC):** Impuesto establecido sobre bienes y servicios específicos, por razones que dependen de cada Estado. Entre las razones más comunes para gravar un bien específico se encuentra, por ejemplo, el carácter indemnizatorio o el desincentivador que se pretende implementar sobre o por el consumo o realización de este. Así, es que las bebidas alcohólicas, el tabaco, y la marihuana
- **Impuestos:** Los Derechos o impuestos a la importación corresponden al monto de tributos que el fisco recauda debido al ingreso de una mercancía extranjera al comercio nacional. (Ministerio de Hacienda, 2024).
- **Ítem:** Línea del DUA donde se describe e indica la cantidad de las mercancías que se presentan para ser destinadas a un régimen aduanero determinado.
- **Ley 6946:** Tarifa de Ley N°6946, de un 1% aplicable sobre el valor aduanero.
- **Localización:** véase Depositario Aduanero.
- **Medio o modo de transporte:** Nave, aeronave, vagón ferroviario, vehículo automotor, o cualquier otro medio utilizado para el transporte de personas o mercancías. (Ministerio de Hacienda, 2021)
- **Mercancía:** Objeto susceptible de ser apropiado y, por ende, importado o exportado, clasificado conforme al arancel de aduanas.
- **Modalidad:** Cada régimen aduanero contará con modalidades según detalle, por ejemplo, la importación puede ser modalidad importación definitiva, temporal, courier, entre otras.
- **Modelo:** De las mercancías que se adquieren, por ejemplo en sitios web y se trasladan a Costa Rica, bajo la modalidad de courier.
- **Nota técnica:** requisitos no arancelarios o autorizaciones preestablecidos por la institución rectora mediante leyes y decretos, que avalan el ingreso o salida de las mercancías del o al territorio nacional. (Ministerio de Hacienda, 2021)
- **País de adquisición:** País en donde se adquirido el servicio o mercancía.

- **País de origen:** País de donde, según lo establecido en el Tratado de Libre Comercio, son originarias las mercancías o servicios.
- **País de procedencia:** País de donde procede la mercancía, que no necesariamente coincide con el país de origen o de adquisición.
- **Peso bruto:** El peso bruto es el peso total de un producto más su empaque o contenedor.
- **Peso neto:** El peso neto de un producto, sea únicamente el peso del producto en sí.
- **Precio FOB:** FOB es un término comercial que pertenece a los Incoterms, corresponde a las siglas en inglés de 'Free on board'. El Precio FOB se determina por: precio de la mercancía, el precio de embalaje y etiquetado, precio por transporte desde la planta de producción hasta el puerto de origen, el precio del seguro de la mercancía durante su traslado a puerto, gastos administrativos generados por la concesión de permisos o licencias, gastos derivados de las autoridades aduaneras, algunos gastos bancarios resultantes de pagos y transferencias internacionales y gastos portuarios, como uso de muelle, elevadores o estiba.
- **PROCOMER:** Promotora de Comercio Exterior de Costa Rica, pago de $3 por cada declaración aduanera transmitida electrónicamente, para la institución.
- **Proveedor:** Persona física o jurídica que suministra profesionalmente un determinado bien o servicio a otros individuos o sociedades, como forma de actividad económica y a cambio de una contra prestación.
- **Régimen:** Diferentes destinaciones a que pueden quedar sujetas las mercancías que se encuentran bajo control aduanero (Art 109. LGA)
- **Seguro:** Protección de la carga desde que sale del depósito del vendedor hasta las bodegas del comprador, o según INCOTERM.
- **Unidad de medida:** Referencia convencional que se usa para medir la magnitud física de un determinado objeto, sustancia o fenómeno.
- **Valor CIF:** Representa el precio total de la mercancía, incluyendo el coste, del seguro y el flete hasta el puerto de destino acordado.
- **Valor en Aduana:** El valor de transacción, o precio realmente pagado o por pagar por las mercancías cuando éstas se venden para su exportación al país de importación.

5 Data Understanding – MJ LO REDACTA

La fase de comprensión de datos de CRISP-DM implica estudiar de cerca los datos disponibles de minería. Este paso es esencial para evitar problemas inesperados durante la siguiente fase (preparación de datos) que suele ser la fase más larga de un proyecto.

Como se señala, el proceso de data understanding es importante para establecer una base sólida para el análisis, permitiendo una comprensión profunda de la estructura y el contenido de la base de datos, que incluye elementos como DUA, Fecha DUA, Código SAC, cantidad, Valor FOB USD, $CostofleteUSD$, Costo seguro USD, $ValorCIFUSD$, Valor en Aduana USD, $Pesobrutoenlibras, DescripcindeMercanca, TotalIVAUSD$, Total Ley 6946 USD, $totalDAIUS$, Total SC USD$ y total de Impuestos. Con un enfoque en tres objetivos específicos: implementar un análisis de cesta utilizando algoritmos de asociación para identificar

patrones de compra y relaciones entre productos, realizar un análisis de tendencias de las mercancías importadas mediante técnicas de series temporales para detectar patrones y cambios en la demanda, y diseñar variables ingenieriles para optimizar los procesos de importación. Esta fase inicial es fundamental para asegurar la calidad y la integridad del análisis subsecuente.

5.1 Carga de archivo de datos fuente

Se inicia con una carga del conjunto de datos, ubicado en la carpeta '/data/raw/' de nuestro directorio. Para evitar problemas de ubicación, se utiliza la variable parent_dir que representa el directorio padre de la solución. Esto se obtuvo al inicio de este notebook

[ ]:
```
# Lectura del archivo de datos y almacenamiento en variable data
data = pd.read_excel (parent_dir + '/data/raw/data.xlsx',␣
 ↪sheet_name='UnifiedData')
# Se despliega los primeros registros de los datos
data.head()
```

[ ]:
```
                DUA  Item del DUA  Fecha DUA      Aduana  \
0  005-2022-001495             1 2022-01-03  SANTAMARIA
1  005-2022-001495             2 2022-01-03  SANTAMARIA
2  005-2022-001495             3 2022-01-03  SANTAMARIA
3  005-2022-001495             4 2022-01-03  SANTAMARIA
4  005-2022-001495             5 2022-01-03  SANTAMARIA

                   Regimen       Modalidad Importador      Proveedor  \
0  IMPORTACION DEFINITIVA  ENTREGA RAPIDA  SwiftShip  No disponible
1  IMPORTACION DEFINITIVA  ENTREGA RAPIDA  SwiftShip  No disponible
2  IMPORTACION DEFINITIVA  ENTREGA RAPIDA  SwiftShip  No disponible
3  IMPORTACION DEFINITIVA  ENTREGA RAPIDA  SwiftShip  No disponible
4  IMPORTACION DEFINITIVA  ENTREGA RAPIDA  SwiftShip  No disponible

            Marca         Modelo  … Total IVA USD  % Ley 6946  \
0  No disponible  No disponible  …          6.45           1
1  No disponible  No disponible  …         92.12           1
2  No disponible  No disponible  …         86.12           1
3  No disponible  No disponible  …         51.21           1
4  No disponible  No disponible  …          9.54           1

   Total Ley 6946 USD % DAI Total DAI USD COSTO por PROCOMER USD % S.C  \
0                0.43    14          6.04                       3     0
1                5.61    14         78.49                       0    10
2                5.76    14         80.65                       0     0
3                3.58     9         32.23                       0     0
4                0.64    14          8.94                       0     0

   Total SC USD Otros impuestos USD  Total de Impuestos
0          0.00                0.11               16.03
1         63.91                0.00              240.13
```

```
2          0.00                0.00              172.53
3          0.00                0.00               87.02
4          0.00                0.00               19.12

[5 rows x 49 columns]
```

5.2 Lectura de catálogos

Se carga la información del catálogo hecho con base en el Sistema Armonizado (SA), es código según se indicó con anterioridad, es una clasificación de mercancías creado por la Organización Mundial de Aduanas (OMA) y está compuesto por 6 dígitos (Subpartidas) con aceptación en casi todo el mundo. Para efectos del proyecto, se utiliza la codificación a nivel de partida (4 dígitos) para facilitar el proceso de interpretación, sin que esto afecte la codificación original de la OMA.

[ ]:
```
# Variable para administrar los datos de los catálogos
data_catalogo = pd.read_excel(parent_dir + '/data/raw/catalogo.xlsx',␣
 ↪sheet_name='Catálogo')

# Despliegue de primeras filas del conjunto de datos
data_catalogo.head()
```

[ ]:
```
   Código Sistema Armonizado  \
0                       9504
1                       8516
2                       3926
3                       9506
4                       9503

                                        Descripción
0  VIDEOCONSOLAS        Y        MÁQUINAS        …
1  CALENTADORES   ELÉCTRICOS   DE   AGUA   DE CAL…
2  LAS   DEMÁS   MANUFACTURAS   DE   PLÁSTICO   Y…
3  ARTÍCULOS   Y   MATERIAL   PARA   CULTURA FÍSI…
4  TRICICLOS, PATINETES, COCHES DE PEDAL Y JUGUET…
```

5.3 Descripción de valores en columnas de datos – Listo

Hacer una descripción de valores en columnas de datos en el proceso de data understanding es esencial para comprender el contenido y la estructura de los datos, identificar problemas de calidad, y detectar patrones y tendencias preliminares. Este análisis inicial permite validar hipótesis, preparar adecuadamente los datos para modelos y algoritmos posteriores, y asegurar una comunicación clara y documentada de los hallazgos. En el proyecto CRISP-DM para SwiftShip y ExpediteX, esto garantiza que las decisiones estratégicas se basen en datos precisos y bien entendidos.

1. **Año**: Año en que se realizaron las importaciones.
2. **DUA**: Documento Único Administrativo, identificador de la operación de importación.
3. **Item**: Número de ítem en la factura.
4. **Fecha**: Fecha de la operación de importación.
5. **Aduana**: Aduana por la que ingresaron los productos.

6. **Regimen**: Régimen aduanero bajo el cual se importaron los productos.
7. **Modalidad**: Modalidad de importación.
8. **Importador**: Empresa que importó los productos.
9. **Proveedor**: Proveedor de los productos importados.
10. **Marca**: Marca de los productos importados.
11. **Modelo**: Modelo de los productos importados.
12. **Factura**: Número de factura de la operación de importación.
13. **Código SAC**: Código del Sistema Armonizado de Designación y Codificación de Mercancías.
14. **Vía Transporte**: Vía por la que se transportaron los productos.
15. **País de Origen**: País de origen de los productos.
16. **Pais de Procedencia**: País de procedencia de los productos.
17. **Pais de Adquisición**: País donde se adquirieron los productos.
18. **Cantidad Comercial**: Cantidad de productos importados.
19. **Unidad de Medida**: Unidad de medida de los productos importados.
20. **Volúmen Físico**: Volumen físico de los productos importados.
21. **Bultos**: Cantidad de bultos en los que se transportaron los productos.
22. **U$S FOB**: Valor FOB (Free On Board) de los productos en dólares estadounidenses.
23. **U$S FOB Unit.**: Valor unitario FOB de los productos en dólares estadounidenses.
24. **U$S Flete**: Costo del flete en dólares estadounidenses.
25. **U$S Seguro**: Costo del seguro en dólares estadounidenses.
26. **U$S CIF**: Valor CIF (Cost, Insurance and Freight) de los productos en dólares estadounidenses.
27. **U$S Unitario**: Valor unitario de los productos en dólares estadounidenses.
28. **Valor en Aduana U$S**: Valor en aduana de los productos en dólares estadounidenses.
29. **Kg netos**: Peso neto de los productos en kilogramos.
30. **Kg brutos**: Peso bruto de los productos en kilogramos.
31. **Descripción de Mercancía**: Descripción de los productos importados.
32. **ID Declarante**: Identificador del declarante.
33. **Declarante**: Nombre del declarante.
34. **ID Agente**: Identificador del agente de aduanas.
35. **Agente**: Nombre del agente de aduanas.
36. **ID Localización**: Identificador de la localización.
37. **Localización**: Localización de la operación de importación.
38. **% IVA**: Porcentaje del Impuesto al Valor Agregado.
39. **IVA - U$S**: Valor del IVA en dólares estadounidenses.
40. **% Ley 6946**: Porcentaje de la Ley 6946.
41. **Ley 6946 U$S**: Valor de la Ley 6946 en dólares estadounidenses.
42. **% DAI**: Porcentaje del Derecho Arancelario de Importación.
43. **DAI U$S**: Valor del DAI en dólares estadounidenses.
44. **PROCOMER U$S**: Valor de PROCOMER en dólares estadounidenses.
45. **% S.C**: Porcentaje de S.C.
46. **S.C. U$S**: Valor de S.C en dólares estadounidenses.
47. **Otros Imp. U$S**: Otros impuestos en dólares estadounidenses.
48. **Total de Impuestos**: Total de impuestos de la operación de importación.
49. **Proporción Pr FOB / impuestos**: Proporción entre el valor FOB y los impuestos.
50. **Proporción VA / impuestos**: Proporción entre el valor en aduana y los impuestos.

5.4 Análisis Estadístico – Listo

Ayuda a entender cómo están distribuidos los datos en términos de frecuencia, media, mediana, moda, rangos y varianza, lo cual permite identificar patrones generales en las importaciones. Al analizar las tendencias a lo largo de los años, codificación de las mercancías importadas, países de origen y procedencia, y otros atributos, se pueden identificar patrones que ayuden a tomar decisiones estratégicas. Además, el análisis descriptivo permite detectar valores atípicos o inconsistencias en los datos, lo cual es crucial para asegurar la calidad y la integridad de la información. Identificar oportunidades para optimizar los procesos de importación, reducir costos y mejorar la eficiencia operativa también se facilita con este análisis. Asegurar que todas las importaciones cumplen con las regulaciones y requisitos legales, incluyendo la correcta aplicación de impuestos y aranceles, es fundamental para el cumplimiento normativo. Finalmente, un análisis descriptivo proporciona una base sólida para la planificación y la elaboración de pronósticos futuros, basados en el análisis de datos históricos.

[ ]:
```
# Métricas descriptivas de los datos
data.describe(include='all')
```

[ ]:

	DUA	Item del DUA	Fecha DUA	\
count	178434	178434.000000	178434	
unique	4176	NaN	NaN	
top	005-2023-732459	NaN	NaN	
freq	480	NaN	NaN	
mean	NaN	63.527013	2022-06-23 05:30:13.497427712	
min	NaN	1.000000	2021-01-04 00:00:00	
25%	NaN	12.000000	2021-08-05 00:00:00	
50%	NaN	46.000000	2022-04-06 00:00:00	
75%	NaN	100.000000	2023-05-17 00:00:00	
max	NaN	480.000000	2023-12-28 00:00:00	
std	NaN	60.202672	NaN	

	Aduana	Regimen	Modalidad	Importador	\
count	178434	178434	178434	178434	
unique	1	1	2	2	
top	SANTAMARIA	IMPORTACION DEFINITIVA	ENTREGA RAPIDA	ExpediteX	
freq	178434	178434	178357	143547	
mean	NaN	NaN	NaN	NaN	
min	NaN	NaN	NaN	NaN	
25%	NaN	NaN	NaN	NaN	
50%	NaN	NaN	NaN	NaN	
75%	NaN	NaN	NaN	NaN	
max	NaN	NaN	NaN	NaN	
std	NaN	NaN	NaN	NaN	

	Proveedor	Marca	Modelo	…	Total IVA USD	\
count	178434	178434	178434	…	178434.000000	
unique	12	16	33	…	NaN	
top	No disponible	No disponible	No disponible	…	NaN	

freq	178393	178357	178357	…	NaN
mean	NaN	NaN	NaN	…	6.062704
min	NaN	NaN	NaN	…	0.000000
25%	NaN	NaN	NaN	…	0.250000
50%	NaN	NaN	NaN	…	2.230000
75%	NaN	NaN	NaN	…	5.790000
max	NaN	NaN	NaN	…	190.890000
std	NaN	NaN	NaN	…	12.400669

	% Ley 6946	Total Ley 6946 USD	% DAI	Total DAI USD	\
count	178434.0	178434.000000	178434.0	178434.000000	
unique	8.0	NaN	11.0	NaN	
top	1.0	NaN	14.0	NaN	
freq	93314.0	NaN	56616.0	NaN	
mean	NaN	0.376309	NaN	3.501689	
min	NaN	0.000000	NaN	0.000000	
25%	NaN	0.000000	NaN	0.000000	
50%	NaN	0.140000	NaN	0.940000	
75%	NaN	0.360000	NaN	3.320000	
max	NaN	11.530000	NaN	161.370000	
std	NaN	0.797761	NaN	8.447561	

	COSTO por PROCOMER USD	% S.C	Total SC USD	Otros impuestos USD	\
count	178434.000000	178434.0	178434.000000	178434.000000	
unique	NaN	16.0	NaN	NaN	
top	NaN	0.0	NaN	NaN	
freq	NaN	96091.0	NaN	NaN	
mean	0.066882	NaN	0.812547	0.003029	
min	0.000000	NaN	0.000000	0.000000	
25%	0.000000	NaN	0.000000	0.000000	
50%	0.000000	NaN	0.000000	0.000000	
75%	0.000000	NaN	0.000000	0.000000	
max	3.000000	NaN	242.510000	12.000000	
std	0.442915	NaN	5.652555	0.065990	

	Total de Impuestos
count	178434.00000
unique	NaN
top	NaN
freq	NaN
mean	10.82316
min	0.00000
25%	0.59000
50%	3.94000
75%	10.43000
max	476.31000
std	23.05286

```
[11 rows x 49 columns]
```

5.5 Verificación de valores nulos – listo

Este proceso implica identificar y manejar cualquier dato faltante en las columnas del dataset. Los valores nulos pueden distorsionar los resultados del análisis y los modelos predictivos, por lo que es fundamental tratarlos adecuadamente.

Para efectos de este estudio, no existen valores nulos en el conjunto de datos por lo que no es necesario tratarlos.

[ ]:
```
# Revisión de valores faltantes
data.isnull().sum()
```

[ ]:
```
DUA                          0
Item del DUA                 0
Fecha DUA                    0
Aduana                       0
Regimen                      0
Modalidad                    0
Importador                   0
Proveedor                    0
Marca                        0
Modelo                       0
Factura                      0
Código SAC                   0
Código Sistema Armonizado    0
Modo transporte              0
País de Origen               0
Pais de Procedencia          0
Pais de Adquisición          0
Cantidad                     0
Unidad de Medida             0
Volúmen Físico               0
Cantidad de bultos           0
Valor FOB USD                0
Valor FOB USD por unidad     0
Costo flete USD              0
Costo seguro USD             0
Valor CIF USD                0
Valor CIF USD  unitario      0
Valor en Aduana USD          0
Peso neto Kg.                0
Peso bruto Kg.               0
Peso bruto en Lbs.           0
Descripción de Mercancía     0
ID Declarante                0
```

```
Declarante                  0
ID Agente Aduanero          0
Agente aduanero             0
ID Localización             0
Localización                0
% IVA                       0
Total IVA USD               0
% Ley 6946                  0
Total Ley 6946 USD          0
% DAI                       0
Total DAI USD               0
COSTO por PROCOMER USD      0
% S.C                       0
Total SC USD                0
Otros impuestos USD         0
Total de Impuestos          0
dtype: int64
```

5.6 Histogramas – listo

Los histogramas representados permiten visualizar la distribución de los datos, identificando patrones y tendencias temporales, tipos de productos más importados y rangos de valores comunes. Facilitan la detección de outliers y variaciones en costos y pesos, ayudando a analizar la eficiencia logística y el impacto económico de las importaciones. Esta representación visual es esencial para optimizar procesos y tomar decisiones estratégicas informadas.

[ ]:
```python
import plotly.express as px

# Lista de columnas específicas para las cuales quieres generar histogramas
columnas_especificas = ['Fecha DUA', 'Código Sistema Armonizado', 'Valor FOB␣
 ↪USD', 'Costo flete USD', 'Costo seguro USD', 'Valor CIF USD','Peso bruto en␣
 ↪Lbs.']

# Crea histogramas para las columnas especificadas
for columna in columnas_especificas:
    fig = px.histogram(data, x=columna, title=f"Histograma de {columna}")
    fig.show()
```

5.7 Comparativa de cantidades importadas por año

TODO: FALTA TEXTO

[ ]:
```python
data['Año'] = data['DUA'].str[4:8]
# Mover la columna Anno a la primera posición
año = data.pop('Año')
data.insert(0, 'Año', año)
data['Año'] = pd.to_datetime(data['Año'])
```

```
def create_pivot_table(data):
    pivot_df = data.pivot_table(index='Año', columns='Importador',␣
 ↪values='Cantidad', aggfunc='sum').reset_index()
    plot_pivot_table(pivot_df)

def plot_pivot_table(pivot_df):

    # Preparar los datos para Plotly
    pivot_df_long = pivot_df.melt(id_vars='Año', var_name='Importador',␣
 ↪value_name='Cantidad')

    # Crear el gráfico de barras con Plotly
    fig = px.bar(pivot_df_long, x='Año', y='Cantidad', color='Importador',␣
 ↪title='Cantidades Importadas por Cada Empresa Cada Año',
                 labels={'Cantidad': 'Cantidad Importada', 'Año': 'Año'},␣
 ↪barmode='stack')

    # Mostrar el gráfico
    fig.show(renderer = "notebook")

create_pivot_table(data)
```

6 Data Preparation

La preparación de datos es la etapa que involucra la limpieza, transformación y organización de los datos brutos para hacerlos aptos para el análisis.

Este proceso incluye la identificación y corrección de datos faltantes, duplicados o inconsistentes en las columnas clave: 'Fecha DUA', 'Código Sistema Armonizado', 'Valor FOB USD', 'Costo flete USD', 'Costo seguro USD', 'Valor CIF USD', y 'Peso bruto en Lbs.'. También implica la normalización y escalado de los valores para asegurar coherencia y precisión en el análisis posterior. La preparación adecuada de los datos garantiza que las inferencias y modelos construidos sean fiables y robustos, permitiendo una toma de decisiones estratégicas basada en datos limpios y bien estructurados.

[ ]:
```
# data['Año'] = data['DUA'].str[4:8]
# # Mover la columna Anno a la primera posición
# año = data.pop('Año')
# data.insert(0, 'Año', año)
# data.head()
```

[ ]:
```
# Se cuenta con información de dos años completos
distinct_values = data['Año'].unique()
print(distinct_values)
```

```
<DatetimeArray>
['2022-01-01 00:00:00', '2023-01-01 00:00:00', '2021-01-01 00:00:00']
Length: 3, dtype: datetime64[ns]
```

[ ]:
```
print(data.columns)
```

```
Index(['Año', 'DUA', 'Item del DUA', 'Fecha DUA', 'Aduana', 'Regimen',
       'Modalidad', 'Importador', 'Proveedor', 'Marca', 'Modelo', 'Factura',
       'Código SAC', 'Código Sistema Armonizado', 'Modo transporte',
       'País de Origen', 'Pais de Procedencia', 'Pais de Adquisición',
       'Cantidad', 'Unidad de Medida', 'Volúmen Físico', 'Cantidad de bultos',
       'Valor FOB USD', 'Valor FOB USD por unidad', 'Costo flete USD',
       'Costo seguro USD', 'Valor CIF USD', 'Valor CIF USD  unitario',
       'Valor en Aduana USD', 'Peso neto Kg.', 'Peso bruto Kg.',
       'Peso bruto en Lbs.', 'Descripción de Mercancía', 'ID Declarante',
       'Declarante', 'ID Agente Aduanero', 'Agente aduanero',
       'ID Localización', 'Localización', '% IVA', 'Total IVA USD',
       '% Ley 6946', 'Total Ley 6946 USD', '% DAI', 'Total DAI USD',
       'COSTO por PROCOMER USD', '% S.C', 'Total SC USD',
       'Otros impuestos USD', 'Total de Impuestos'],
      dtype='object')
```

Proceso de creación y conexión a base de datos

Una vez ordenados y definida la información es necesario respaldar los datos en la base de datos. Para esto, se utiliza una base de datos SQLlite para almacenarlos.

ESTO HAY QUE DEFINIR PARA QUÉ nos sirve

6.1 Análisis de la cantidad de DUAs por Mes y Código SAC

Para realizar un análisis más detallado de la cantidad de DUAs por mes y código SAC, hemos utilizado Python y Plotly para crear un gráfico de barras interactivo. Este gráfico nos permite visualizar la distribución de la cantidad de DUAs para un importador específico en un año determinado.

6.1.1 Procedimiento

1. **Filtrado de datos**: Primero, hemos filtrado los datos para seleccionar un año específico y un importador particular. En este caso, hemos seleccionado el año 2022 y el importador 'LIBERTY EXPRESS CORPORATE VC SOCIEDAD AN'.
2. **Agrupación de datos**: Luego, hemos agrupado los datos filtrados por mes y código SAC, contando la cantidad de DUAs en cada grupo.
3. **Creación del gráfico de barras**: Utilizando Plotly Express, hemos creado un gráfico de barras que muestra la cantidad de DUAs por mes y código SAC para el año e importador seleccionados. Cada barra representa la cantidad de DUAs asociadas a un código SAC específico en un mes determinado.

6.1.2 Interpretación

Este gráfico nos permite identificar patrones o tendencias en la distribución de la cantidad de DUAs para el importador seleccionado a lo largo del año 2022. Podemos observar qué tipos de productos (definidos por el código SAC) tienen una mayor o menor incidencia en diferentes meses del año, lo

que puede proporcionar información útil para la planificación y la toma de decisiones estratégicas en la gestión de importaciones.

[ ]:
```
# Asegurarse de que 'Mes' se extrae correctamente si 'Año' es una columna de␣
 ↪tipo fecha

data['Mes'] = data['Año'].dt.month

# Agrupar los datos por año, importador, mes y Código SAC y contar la cantidad␣
 ↪de DUAs
duas_por_año_importador_mes_sac = data.groupby([data['Año'].dt.year,␣
 ↪'Importador', 'Mes', 'Código Sistema Armonizado']).size().
 ↪reset_index(name='Cantidad_DUAs')

# Crear el gráfico para todos los importadores y años
fig = px.bar(duas_por_año_importador_mes_sac, x='Mes', y='Cantidad_DUAs',␣
 ↪color='Código Sistema Armonizado',
             facet_col='Año', facet_row='Importador',
             labels={'Mes': 'Mes', 'Cantidad_DUAs': 'Cantidad de DUAs', 'Código␣
 ↪Sistema Armonizado': 'Código SA'},
             width=800, height=600)

# Actualizar el diseño del gráfico
fig.update_layout(title='Cantidad de DUAs por Mes y Código Sistema Armonizado␣
 ↪para todos los importadores y años',
                   xaxis_title='Mes', yaxis_title='Cantidad de DUAs')

# Mostrar el gráfico
fig.show()
```

[ ]:
```
# Agrupar los datos por año, importador, mes y Código SAC y contar la cantidad␣
 ↪de DUAs
data['Mes'] = data['Año'].str[5:7]
duas_por_año_importador_mes_sac = data.groupby(['Año', 'Importador', 'Mes',␣
 ↪'Código Sistema Armonizado']).size().reset_index(name='Cantidad_DUAs')

# Crear el gráfico para todos los importadores y años
fig = px.bar(duas_por_año_importador_mes_sac, x='Mes', y='Cantidad_DUAs',␣
 ↪color='Código Sistema Armonizado',
             facet_col='Año', facet_row='Importador',
             labels={'Mes': 'Mes', 'Cantidad_DUAs': 'Cantidad de DUAs', 'Código␣
 ↪SA': 'Código Sistema Armonizado'},
             width=800, height=600)

# Actualizar el diseño del gráfico
fig.update_layout(title='Cantidad de DUAs por Mes y Código Sistema Armonizado␣
 ↪para todos los importadores y años',
```

```
                  xaxis_title='Mes', yaxis_title='Cantidad de DUAs')

# Mostrar el gráfico
fig.show()
```

```
---------------------------------------------------------------------------
AttributeError                            Traceback (most recent call last)
Cell In[13], line 2
      1 # Agrupar los datos por año, importador, mes y Código SAC y contar la␣
 ↪cantidad de DUAs
----> 2 data['Mes'] = data['Año'].str[5:7]
      3 duas_por_año_importador_mes_sac = data.groupby(['Año', 'Importador',␣
 ↪'Mes', 'Código Sistema Armonizado']).size().reset_index(name='Cantidad_DUAs')
      5 # Crear el gráfico para todos los importadores y años

File ~/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-packages/pandas/
 ↪core/generic.py:5989, in NDFrame.__getattr__(self, name)
   5982 if (
   5983     name not in self._internal_names_set
   5984     and name not in self._metadata
   5985     and name not in self._accessors
   5986     and self._info_axis._can_hold_identifiers_and_holds_name(name)
   5987 ):
   5988     return self[name]
-> 5989 return object.__getattribute__(self, name)

File ~/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-packages/pandas/
 ↪core/accessor.py:224, in CachedAccessor.__get__(self, obj, cls)
    221 if obj is None:
    222     # we're accessing the attribute of the class, i.e., Dataset.geo
    223     return self._accessor
--> 224 accessor_obj = self._accessor(obj)
    225 # Replace the property with the accessor object. Inspired by:
    226 # https://www.pydanny.com/cached-property.html
    227 # We need to use object.__setattr__ because we overwrite __setattr__ on
    228 # NDFrame
    229 object.__setattr__(obj, self._name, accessor_obj)

File ~/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-packages/pandas/
 ↪core/strings/accessor.py:181, in StringMethods.__init__(self, data)
    178 def __init__(self, data) -> None:
    179     from pandas.core.arrays.string_ import StringDtype
--> 181     self._inferred_dtype = self._validate(data)
    182     self._is_categorical = is_categorical_dtype(data.dtype)
    183     self._is_string = isinstance(data.dtype, StringDtype)
```

```
File ~/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-packages/pandas/
 ↪core/strings/accessor.py:235, in StringMethods._validate(data)
    232 inferred_dtype = lib.infer_dtype(values, skipna=True)
    234 if inferred_dtype not in allowed_types:
--> 235     raise AttributeError("Can only use .str accessor with string values
 ↪")
    236 return inferred_dtype

AttributeError: Can only use .str accessor with string values!
```

[ ]:
```
duas_por_año_importador_mes_sac = data.groupby(['Año', 'Importador', 'Mes',␣
 ↪'Código Sistema Armonizado']).size().reset_index(name='Cantidad_DUAs')
# Iterar sobre cada importador único
for importador in data['Importador'].unique():
    # Filtrar el DataFrame para el importador actual
    df_filtrado = data[data['Importador'] == importador]

    # Crear el gráfico para el importador actual
    fig = px.bar(df_filtrado, x='Mes', y='Cantidad DUAs', color='Código Sistema␣
 ↪Armonizado',
                 title=f'Cantidad de DUAs por Mes y Código SA para␣
 ↪{importador}')

    # Mostrar el gráfico
    fig.show()
```

```
---------------------------------------------------------------------------
ValueError                                Traceback (most recent call last)
Cell In[34], line 8
      5 df_filtrado = data[data['Importador'] == importador]
      7 # Crear el gráfico para el importador actual
----> 8 fig =␣
 ↪px.bar(df_filtrado, x='Mes', y='Cantidad DUAs', color='Código Sistema Armoniz ↩do',
      9␣
 ↪             title=f'Cantidad de DUAs por Mes y Código SA para {importador}')
     11 # Mostrar el gráfico
     12 fig.show()

File ~/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-packages/plotly/
 ↪express/_chart_types.py:373, in bar(data_frame, x, y, color, pattern_shape,␣
 ↪facet_row, facet_col, facet_col_wrap, facet_row_spacing, facet_col_spacing,␣
 ↪hover_name, hover_data, custom_data, text, base, error_x, error_x_minus,␣
 ↪error_y, error_y_minus, animation_frame, animation_group, category_orders,␣
 ↪labels, color_discrete_sequence, color_discrete_map, color_continuous_scale,␣
 ↪pattern_shape_sequence, pattern_shape_map, range_color,␣
 ↪color_continuous_midpoint, opacity, orientation, barmode, log_x, log_y,␣
 ↪range_x, range_y, text_auto, title, template, width, height)
    325 def bar(
    326     data_frame=None,
```

```
    327     x=None,
   (…)
    367     height=None,
    368 ) -> go.Figure:
    369     """
    370     In a bar plot, each row of `data_frame` is represented as a␣
 ↪rectangular
    371     mark.
    372     """
--> 373     return make_figure(
    374         args=locals(),
    375         constructor=go.Bar,
    376         trace_patch=dict(textposition="auto"),
    377         layout_patch=dict(barmode=barmode),
    378     )

File ~/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-packages/plotly/
 ↪express/_core.py:2090, in make_figure(args, constructor, trace_patch,␣
 ↪layout_patch)
   2087 layout_patch = layout_patch or {}
   2088 apply_default_cascade(args)
-> 2090 args = build_dataframe(args, constructor)
   2091 if constructor in [go.Treemap, go.Sunburst, go.Icicle] and args["path"]
 ↪is not None:
   2092     args = process_dataframe_hierarchy(args)

File ~/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-packages/plotly/
 ↪express/_core.py:1492, in build_dataframe(args, constructor)
   1489     args["color"] = None
   1490 # now that things have been prepped, we do the systematic rewriting of␣
 ↪`args`
-> 1492 df_output, wide_id_vars = process_args_into_dataframe(
   1493     args, wide_mode, var_name, value_name
   1494 )
   1496 # now that `df_output` exists and `args` contains only references, we␣
 ↪complete
   1497 # the special-case and wide-mode handling by further rewriting args and
 ↪or mutating
   1498 # df_output
   1500 count_name = _escape_col_name(df_output, "count", [var_name, value_name])

File ~/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-packages/plotly/
 ↪express/_core.py:1213, in process_args_into_dataframe(args, wide_mode,␣
 ↪var_name, value_name)
   1211         if argument == "index":
   1212             err_msg += "\n To use the index, pass it in directly as `df
 ↪index`."
-> 1213         raise ValueError(err_msg)
```

```
   1214 elif length and len(df_input[argument]) != length:
   1215     raise ValueError(
   1216         "All arguments should have the same length. "
   1217         "The length of column argument `df[%s]` is %d, whereas the "
   (…)
   1224         )
   1225     )

ValueError: Value of 'y' is not the name of a column in 'data_frame'. Expected␣
 ↪one of ['Año', 'DUA', 'Item del DUA', 'Fecha DUA', 'Aduana', 'Regimen',␣
 ↪'Modalidad', 'Importador', 'Proveedor', 'Marca', 'Modelo', 'Factura', 'Código
 ↪SAC', 'Código Sistema Armonizado', 'Modo transporte', 'País de Origen', 'Pais
 ↪de Procedencia', 'Pais de Adquisición', 'Cantidad', 'Unidad de Medida',␣
 ↪'Volúmen Físico', 'Cantidad de bultos', 'Valor FOB USD', 'Valor FOB USD por␣
 ↪unidad', 'Costo flete USD', 'Costo seguro USD', 'Valor CIF USD', 'Valor CIF␣
 ↪USD  unitario', 'Valor en Aduana USD', 'Peso neto Kg.', 'Peso bruto Kg.',␣
 ↪'Peso bruto en Lbs.', 'Descripción de Mercancía', 'ID Declarante',␣
 ↪'Declarante', 'ID Agente Aduanero', 'Agente aduanero', 'ID Localización',␣
 ↪'Localización', '% IVA', 'Total IVA USD', '% Ley 6946', 'Total Ley 6946 USD',
 ↪'% DAI', 'Total DAI USD', 'COSTO por PROCOMER USD', '% S.C', 'Total SC USD',␣
 ↪'Otros impuestos USD', 'Total de Impuestos', 'Descripción ', 'Mes'] but␣
 ↪received: Cantidad DUAs
```

Este código es útil para el análisis de datos ya que permite visualizar las 20 principales operaciones de importación (DUAs) en términos de U$S FOB. FOB (Free On Board) es un término de comercio internacional que indica el valor de los bienes en el punto de embarque, es decir, el valor de los bienes antes de ser exportados.

Al visualizar estos datos, los analistas pueden identificar rápidamente cuáles son las operaciones de importación más valiosas en términos de U$S FOB. Esto puede ser útil para identificar tendencias, patrones o anomalías en los datos, lo que puede informar decisiones comerciales o estratégicas

[ ]:
```python
def plot_top_20_duas(data):
    """
    Grafica las 20 principales DUAs por Valor FOB USD utilizando plotly.express.

    Parámetros:
    - data (pandas.DataFrame): El DataFrame de entrada que contiene los datos.

    Retorna:
    - None
    """

    # Obtener las 20 principales DUAs por cantidad
    top_20_duas = data['DUA'].value_counts().head(20).index

    # Filtrar los datos para incluir solo las DUAs seleccionadas
    filtered_data = data[data['DUA'].isin(top_20_duas)]

    # Agrupar los datos por DUA y sumar los valores de Valor FOB USD
```

```
    aggregated_data = filtered_data.groupby('DUA')['Valor CIF USD'].sum().
 ↪reset_index()

    # Ordenar los datos por Valor FOB USD de forma descendente
    aggregated_data = aggregated_data.sort_values(by='Valor CIF USD',␣
 ↪ascending=False)

    # Crear el gráfico de barras utilizando plotly express
    fig = px.bar(aggregated_data, x='DUA', y='Valor CIF USD',
                 labels={'DUA': 'DUA', 'Valor CIF USD': 'Valor CIF USD'},
                 title='Top 20 DUAs por Valor CIF USD')
    fig.update_layout(xaxis_tickangle=-90)
    fig.show(renderer = "notebook")

plot_top_20_duas(data)
```

??? Porque CIF?

[ ]:

U$S CIF vs. Kg netos: Esta comparación puede ayudar a entender si hay alguna relación entre el costo de las mercancías y su peso neto. Podría ser útil para identificar si los productos más pesados tienden a ser más costosos o si existe alguna otra relación entre estas dos variables.

PENDIENTE DEFINIR SI ESTO NOS SIRVE

[ ]:
```
# Importar plotly.express como px

# Crear el gráfico de dispersión con diferentes colores basados en el␣
 ↪importador y con información adicional al pasar el mouse sobre 'Descripción␣
 ↪de Mercancía'
fig_cif_vs_kg = px.scatter(data, x='Peso neto Kg.', y='Valor CIF USD',␣
 ↪color='Importador',
                           title='Valor CIF USD vs. Kg netos',
                           hover_data={'Descripción de Mercancía': True})

# Mostrar el gráfico
fig_cif_vs_kg.show(renderer = "notebook")
```

[ ]:

6.2 U$S CIF vs. Año con Importador

Comparar el costo de las mercancías a lo largo de los años puede revelar tendencias o patrones en los precios a lo largo del tiempo. Agregar la variable 'Importador' al gráfico de dispersión nos permite examinar cómo varía el costo CIF en función del año, y además nos brinda información sobre diferentes importadores y su impacto en los precios. Esto puede ser útil para identificar si hay algún importador en particular que tenga una influencia significativa en los costos de las

mercancías a lo largo de los años, lo que podría llevar a investigaciones adicionales sobre prácticas de importación, cambios en los proveedores o políticas comerciales.

6.2.1 idea de gráfico 1

ESTO NO ME GUSTA

[ ]:
```
# Crear el gráfico de dispersión para U$S CIF vs. Anno con la variable␣
↪'Importador'
fig_cif_anno_importador = px.scatter(data, x='Año', y='Valor CIF USD',␣
↪color='Importador',
                                     title='U$S CIF vs. Año con Importador',
                                     labels={'Año': 'Año', 'U$S CIF': 'Valor␣
↪CIF US'},
                                     width=800, height=600)

# Mostrar el gráfico
fig_cif_anno_importador.show(renderer = "notebook")
```

6.3 Almacenamiento en base de datos —- REvisar

Se almacena el conjunto de datos ya procesado en un motor de base de datos SQLite.

[ ]:
```
# Connect to the SQLite database
# SalvarEnBD('FactDatosCouriers', data)
```

6.4 Ingeniería de variables

Se agregan dos variables al conjunto de datos para obtener información adicional durante el análisis

- Proporción de impuestos sobre el valor FOB: Incluir como ayuda esto al análisis
- Proporción de impuestso sobre el valor aduanero

[ ]:
```
data['Proporción de impuestos sobre el valor FOB'] = (data['Total de␣
↪Impuestos'] * data["Valor FOB USD"]) / 100
data['Proporción de los impuestos sobre el valor aduanero'] = (data['Total de␣
↪Impuestos'] * data["Valor en Aduana USD"]) / 100
```

6.5 Unificación de datos

Se unifican ambas fuentes de datos en un solo archivo para darle tratamiento durante este proyecto. Esto se hace realizando un inner join entre ambos conjuntos de datos, y de esta manera poder contar con las descripciones para todas las partidas

[ ]:
```
data = data.merge(data_catalogo, left_on='Código Sistema Armonizado',␣
↪right_on='Código Sistema Armonizado')
data.head()
```

[ ]:
```
          Año              DUA  Item del DUA  Fecha DUA      Aduana  \
0 2022-01-01  005-2022-001495             1 2022-01-03  SANTAMARIA
```

```
1 2022-01-01  005-2022-001500            11 2022-01-03  SANTAMARIA
2 2022-01-01  005-2022-001501             8 2022-01-03  SANTAMARIA
3 2022-01-01  005-2022-040801             8 2022-01-24  SANTAMARIA
4 2022-01-01  005-2022-040801             9 2022-01-24  SANTAMARIA

                 Regimen       Modalidad Importador      Proveedor  \
0  IMPORTACION DEFINITIVA  ENTREGA RAPIDA  SwiftShip  No disponible
1  IMPORTACION DEFINITIVA  ENTREGA RAPIDA  SwiftShip  No disponible
2  IMPORTACION DEFINITIVA  ENTREGA RAPIDA  SwiftShip  No disponible
3  IMPORTACION DEFINITIVA  ENTREGA RAPIDA  SwiftShip  No disponible
4  IMPORTACION DEFINITIVA  ENTREGA RAPIDA  SwiftShip  No disponible

          Marca  … COSTO por PROCOMER USD % S.C  Total SC USD  \
0  No disponible  …                       3     0           0.0
1  No disponible  …                       0     0           0.0
2  No disponible  …                       0     0           0.0
3  No disponible  …                       0     0           0.0
4  No disponible  …                       0     0           0.0

   Otros impuestos USD Total de Impuestos  \
0                 0.11              16.03
1                 0.00             257.99
2                 0.00             123.87
3                 0.00              21.35
4                 0.00              24.37

                                    Descripción _x Mes  \
0  VIDEOCONSOLAS        Y        MÁQUINAS        …   1
1  VIDEOCONSOLAS        Y        MÁQUINAS        …   1
2  VIDEOCONSOLAS        Y        MÁQUINAS        …   1
3  VIDEOCONSOLAS        Y        MÁQUINAS        …   1
4  VIDEOCONSOLAS        Y        MÁQUINAS        …   1

  Proporción de impuestos sobre el valor FOB  \
0                                   5.289900
1                                2176.610032
2                                 495.467613
3                                  12.807865
4                                  17.059000

   Proporción de los impuestos sobre el valor aduanero  \
0                                           6.918548
1                                        2222.377458
2                                         512.301546
3                                          15.220415
4                                          19.834743
```

```
                                    Descripción _y
0  VIDEOCONSOLAS        Y        MÁQUINAS        …
1  VIDEOCONSOLAS        Y        MÁQUINAS        …
2  VIDEOCONSOLAS        Y        MÁQUINAS        …
3  VIDEOCONSOLAS        Y        MÁQUINAS        …
4  VIDEOCONSOLAS        Y        MÁQUINAS        …

[5 rows x 55 columns]
```

7 3. MODELADO

7.1 Basket Analysis utilizando el algoritmo Apriori

7.1.1 Paso 1: Preparación de los datos

En el primer paso del Basket Analysis, estamos preparando nuestros datos para el análisis. Los datos deben estar en un formato específico para que el algoritmo Apriori pueda procesarlos. Este formato se conoce como "one-hot encoding".

En "one-hot encoding", cada fila de los datos representa una transacción (en nuestro caso, identificada por la columna 'DUA') y cada columna representa un artículo (identificado por la columna 'Código Sistema Armonizado). Si un artículo específico está presente en una transacción, el valor en la celda correspondiente es 1, y si no está presente, el valor es 0.

Esto nos permite tener una representación binaria de nuestras transacciones, que es el formato requerido para el algoritmo Apriori.

[ ]:
```
# Agrupamos por 'DUA' y 'DescripcionPartida', deshacemos el apilamiento de los␣
 ↪artículos y llenamos los valores NA con 0
basket = (data
          .groupby(['DUA', 'Código Sistema Armonizado'])['Código Sistema␣
 ↪Armonizado']
          .count().unstack().reset_index().fillna(0)
          .set_index('DUA'))

# Convertimos las unidades a valores codificados en caliente (1 hot encoded)
def codificar_unidades(x):
    if x <= 0:
        return 0
    if x >= 1:
        return 1

conjuntos_cesta = basket.applymap(codificar_unidades)

# Mostramos las primeras filas del DataFrame resultante
conjuntos_cesta.head()
```

[ ]:
```
Código Sistema Armonizado  2508  2513  2526  3006  3402  3405  3406  3407  \
DUA
005-2021-000324               0     0     0     0     0     0     0     0
005-2021-000341               0     0     0     0     0     0     0     0
005-2021-002548               0     0     0     0     0     0     0     0
005-2021-002659               0     0     0     0     0     0     0     0
005-2021-002660               0     0     0     0     0     0     0     0

Código Sistema Armonizado  3506  3701  …  9613  9614  9615  9616  9617  \
DUA                                    …
005-2021-000324               0     0  …     0     0     0     0     1
005-2021-000341               0     0  …     0     0     0     0     0
005-2021-002548               0     0  …     0     0     0     0     0
005-2021-002659               0     0  …     0     0     0     0     0
005-2021-002660               0     0  …     0     0     0     0     0

Código Sistema Armonizado  9618  9619  9620  9701  9706
DUA
005-2021-000324               0     0     1     0     0
005-2021-000341               0     0     1     0     0
005-2021-002548               0     0     0     0     0
005-2021-002659               0     0     0     0     0
005-2021-002660               0     0     0     0     0

[5 rows x 456 columns]
```

[ ]:
```
#Salvar el resultado en la base de datos
#SalvarEnBD('BasketAnalysis_OneHotEncoding', data)
# No se guarda en base de datos por tamaño del archivo
```

7.1.2 Paso 2: Generación de conjuntos de artículos frecuentes

El siguiente paso en el Basket Analysis es generar conjuntos de artículos frecuentes. Estos son conjuntos de artículos que aparecen juntos en las transacciones con más frecuencia que un umbral especificado. Para hacer esto, utilizamos la función apriori de la biblioteca mlxtend.

La función apriori toma dos argumentos principales: el DataFrame que contiene nuestros datos y un valor mínimo de soporte. El soporte es una medida de cuán frecuentemente aparece un conjunto de artículos en las transacciones. Al especificar un valor mínimo de soporte, le decimos a la función apriori que sólo queremos los conjuntos de artículos que aparecen en al menos ese porcentaje de las transacciones.

Para efectos de este estudio, se define el valor mínimo de soporte en 0.20

[ ]:
```
# Construimos los conjuntos de artículos frecuentes
conjuntos_cesta_bool = conjuntos_cesta.astype(bool)

# Generate frequent itemsets
```

```
conjuntos_frecuentes = apriori(conjuntos_cesta_bool, min_support=0.20,␣
 ↪use_colnames=True)

# Display the first few frequent itemsets
conjuntos_frecuentes.head()
```

[ ]:
```
    support itemsets
0  0.217672   (3923)
1  0.297653   (3924)
2  0.511734   (3926)
3  0.210010   (4016)
4  0.534962   (4202)
```

7.1.3 Paso 3: Generación de las reglas

En este paso, generamos las reglas a partir de los conjuntos de ítems frecuentes. Estas reglas representan patrones en los datos donde la presencia de ciertos ítems en una transacción implica la presencia de otros ítems. Para hacer esto, utilizamos la función association_rules de la biblioteca mlxtend.

La función association_rules toma dos argumentos principales: el DataFrame de conjuntos de ítems frecuentes y una métrica para evaluar las reglas. La métrica puede ser 'support', 'confidence' o 'lift', y determina qué reglas se consideran interesantes. También especificamos un umbral mínimo para la métrica.

[ ]:
```
# Generate the rules
rules = association_rules(conjuntos_frecuentes, metric="confidence",␣
 ↪min_threshold=0.70)    ## Lo que indicó Ramón hay que documentarlo

# Display the first few rules
rules.head()
```

[ ]:
```
  antecedents consequents  antecedent support  consequent support   support  \
0      (3924)      (3926)            0.297653            0.511734  0.227969
1      (3924)      (4202)            0.297653            0.534962  0.238266
2      (3924)      (4901)            0.297653            0.358477  0.209531
3      (3924)      (6404)            0.297653            0.370450  0.209531
4      (3924)      (9503)            0.297653            0.623084  0.253113

   confidence      lift  leverage  conviction  zhangs_metric
0    0.765889  1.496655  0.075650    2.085619       0.472478
1    0.800483  1.496337  0.079033    2.330817       0.472275
2    0.703942  1.963702  0.102829    2.166883       0.698740
3    0.703942  1.900234  0.099265    2.126441       0.674523
4    0.850362  1.364762  0.067650    2.518851       0.380541
```

Aqui se guardan las reglas en un archivo xlsx para su análisis

[ ]:
```
# Specify the file path and name for the Excel file
file_path = parent_dir + '/data/procesed/rules.xlsx'

# Export the DataFrame to Excel
rules.to_excel(file_path, index=False)
```

7.1.4 Paso 4: Análisis e Interpretación de las Reglas

[ ]:
```
# Ordenamos las reglas por lift en orden descendente, siguiendo consejo de D.␣
 ↪Ramón
reglas_ordenadas_por_lift = rules.sort_values('lift', ascending=False)

# Mostramos las primeras reglas
reglas_ordenadas_por_lift.head()
```

[ ]:
```
            antecedents         consequents  antecedent support  \
825  (6404, 4901, 9503)              (6403)            0.257184
830              (6403)  (6404, 4901, 9503)            0.236351
828        (6403, 9503)        (6404, 4901)            0.229646
829        (6404, 4901)        (6403, 9503)            0.266284
915  (4202, 6404, 3926)        (4901, 8471)            0.245929

     consequent support   support  confidence      lift  leverage  conviction  \
825            0.236351  0.200192    0.778399  3.293406  0.139406    3.446048
830            0.257184  0.200192    0.847011  3.293406  0.139406    4.855361
828            0.266284  0.200192    0.871741  3.273734  0.139041    5.720602
829            0.229646  0.200192    0.751799  3.273734  0.139041    3.103747
915            0.252155  0.200431    0.814995  3.232117  0.138419    4.042298

     zhangs_metric
825       0.937464
830       0.911888
828       0.901583
829       0.946603
915       0.915836
```

[ ]:
```
rules['antecedents'] = rules['antecedents'].apply(list)
rules['consequents'] = rules['consequents'].apply(list)

# Create the scatter plot
fig = px.scatter(rules, x="support", y="confidence", size="lift",
                 hover_data=['antecedents', 'consequents'],
                 size_max=60, title="Reglas de Asociación: Soporte vs.␣
 ↪Confianza")

# Update axes titles
fig.update_xaxes(title_text='Soporte')
```

```
fig.update_yaxes(title_text='Confianza')

# Adjust the height of the plot
fig.update_layout(height=800)  # Set the height to 800 pixels

# Show the plot
fig.show(renderer = "notebook")
```

[ ]:
```
import networkx as nx
import plotly.graph_objects as go

# Create a graph
G = nx.Graph()


# Add nodes and edges from the rules DataFrame
for _, row in rules.iterrows():
    antecedents = ', '.join(str(item) for item in row['antecedents'])
    consequents = ', '.join(str(item) for item in row['consequents'])
    G.add_node(antecedents, type='antecedent')
    G.add_node(consequents, type='consequent')
    G.add_edge(antecedents, consequents, weight=row['lift'])

# Adjust the spring layout with a larger k value for more separation
pos = nx.spring_layout(G, k=0.15)  # Increase k to spread nodes further apart

# Create edge traces
edge_x = []
edge_y = []
for edge in G.edges():
    x0, y0 = pos[edge[0]]
    x1, y1 = pos[edge[1]]
    edge_x.extend([x0, x1, None])
    edge_y.extend([y0, y1, None])

edge_trace = go.Scatter(x=edge_x, y=edge_y, line=dict(width=0.5, color='#888'),␣
 ↪hoverinfo='none', mode='lines')

# Create node traces
node_x = []
node_y = []
text = []
for node in G.nodes():
    x, y = pos[node]
    node_x.append(x)
    node_y.append(y)
    text.append(node)
```

```
node_trace = go.Scatter(x=node_x, y=node_y, text=text, mode='markers+text',␣
 ↪hoverinfo='text', marker=dict(showscale=True, colorscale='YlGnBu', size=10))

# Adjust the figure layout to make it taller and possibly wider
fig = go.Figure(data=[edge_trace, node_trace],
                layout=go.Layout(showlegend=False, hovermode='closest',
                                 margin=dict(b=0,l=0,r=0,t=0),
                                 xaxis=dict(showgrid=False, zeroline=False,␣
 ↪showticklabels=False),
                                 yaxis=dict(showgrid=False, zeroline=False,␣
 ↪showticklabels=False),
                                 height=800,  # Increase height for a taller␣
 ↪plot
                                 width=1400))  # Optional: Adjust width as␣
 ↪needed

# Show the plot
fig.show(renderer = "notebook")
```

AQUI SERIA IMPORTANTE METER la info de las reglas más representativas

[ ]:
```
import pandas as pd

# Assuming 'data' is your DataFrame and 'Código Sistema Armonizado' is the␣
 ↪column you're working with
distinct_values = data['Código Sistema Armonizado'].unique()

# Convert the NumPy array to a DataFrame
distinct_values_df = pd.DataFrame(distinct_values, columns=['Código Sistema␣
 ↪Armonizado'])

# Specify the file path and name for the Excel file
file_path = parent_dir + '/data/distinctValues.xlsx'

# Export the DataFrame to Excel
distinct_values_df.to_excel(file_path, index=False)
#distinct_values.to_excel(file_path, index=False)
```

7.2 Análisis de series temporales

7.2.1 Paso 1: Preparación de los Datos para Análisis de Serie Temporal

En el primer paso de nuestro análisis de serie temporal, nos enfocamos en preparar los datos para su posterior exploración y modelado. Este proceso implica agrupar los datos según fechas específicas y sumar los valores asociados para cada grupo. El objetivo es obtener una visión clara de cómo se comporta la variable de interés ('Valor CIF USD') a lo largo del tiempo.

[ ]:
```
grouped_data = data.groupby('Fecha DUA')['Valor CIF USD'].sum().reset_index()
grouped_data.head()
```

[ ]:
```
   Fecha DUA  Valor CIF USD
0 2021-01-04        7226.16
1 2021-01-05       16784.84
2 2021-01-06       12538.98
3 2021-01-07        6144.09
4 2021-01-08        6306.10
```

7.2.2 Paso 2: Preparación de Datos para Modelado con Prophet

Después de agrupar y sumar los datos en el paso anterior, el siguiente paso en nuestro análisis de serie temporal es preparar los datos específicamente para el modelado con la biblioteca Prophet de Facebook. Prophet espera que los nombres de las columnas de la serie temporal sean 'ds' para la fecha y 'y' para la variable que queremos predecir.

[ ]:
```
df_prophet = grouped_data[['Fecha DUA', 'Valor CIF USD']].
  ↪rename(columns={'Fecha DUA': 'ds', 'Valor CIF USD': 'y'})
```

[ ]:
```
m = Prophet()
m.fit(df_prophet)
```

```
19:53:26 - cmdstanpy - INFO - Chain [1] start processing
19:53:26 - cmdstanpy - INFO - Chain [1] done processing
```

[ ]:
```
<prophet.forecaster.Prophet at 0x336e42700>
```

[ ]:
```
future = m.make_future_dataframe(periods=90)
future.tail()
```

[ ]:
```
            ds
689 2024-03-23
690 2024-03-24
691 2024-03-25
692 2024-03-26
693 2024-03-27
```

[ ]:
```
forecast = m.predict(future)
forecast[['ds', 'yhat', 'yhat_lower', 'yhat_upper']].tail()
```

[ ]:
```
            ds          yhat    yhat_lower    yhat_upper
689 2024-03-23   5408.531618  -5666.506363  15698.244735
690 2024-03-24  11028.792346    489.920527  22196.306777
691 2024-03-25  23015.240779  12613.741200  33646.472568
692 2024-03-26  13026.895353   2481.556840  23517.677077
693 2024-03-27  13384.097071   3019.215279  23734.395824
```

[ ]:
```
fig1 = m.plot(forecast)
```

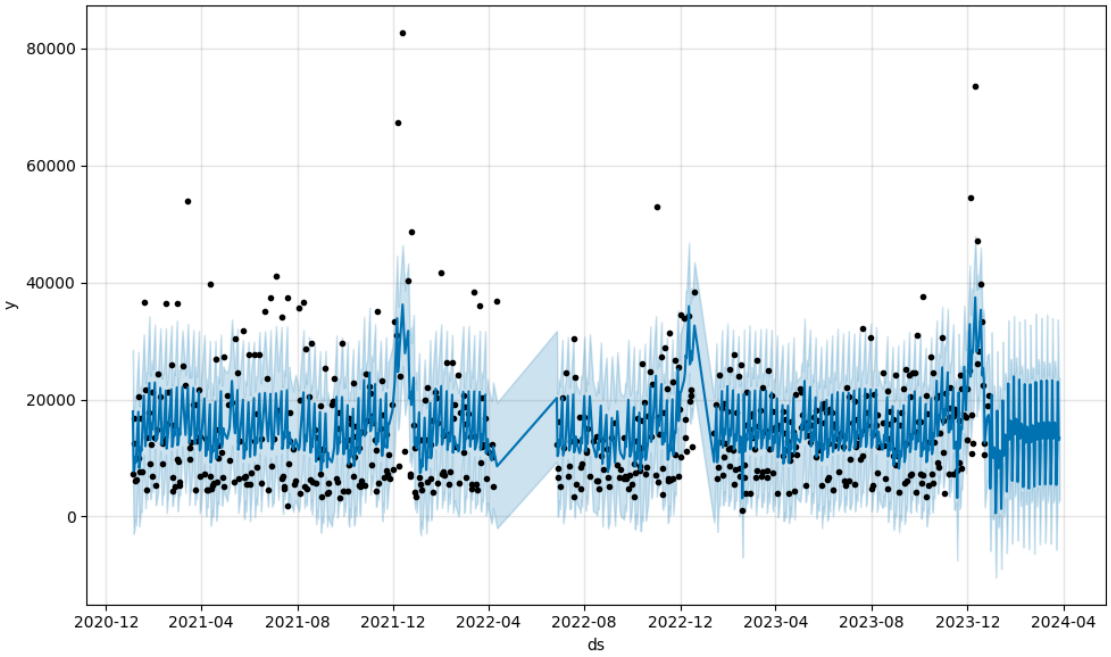

[ ]:
```
fig2 = m.plot_components(forecast)
```

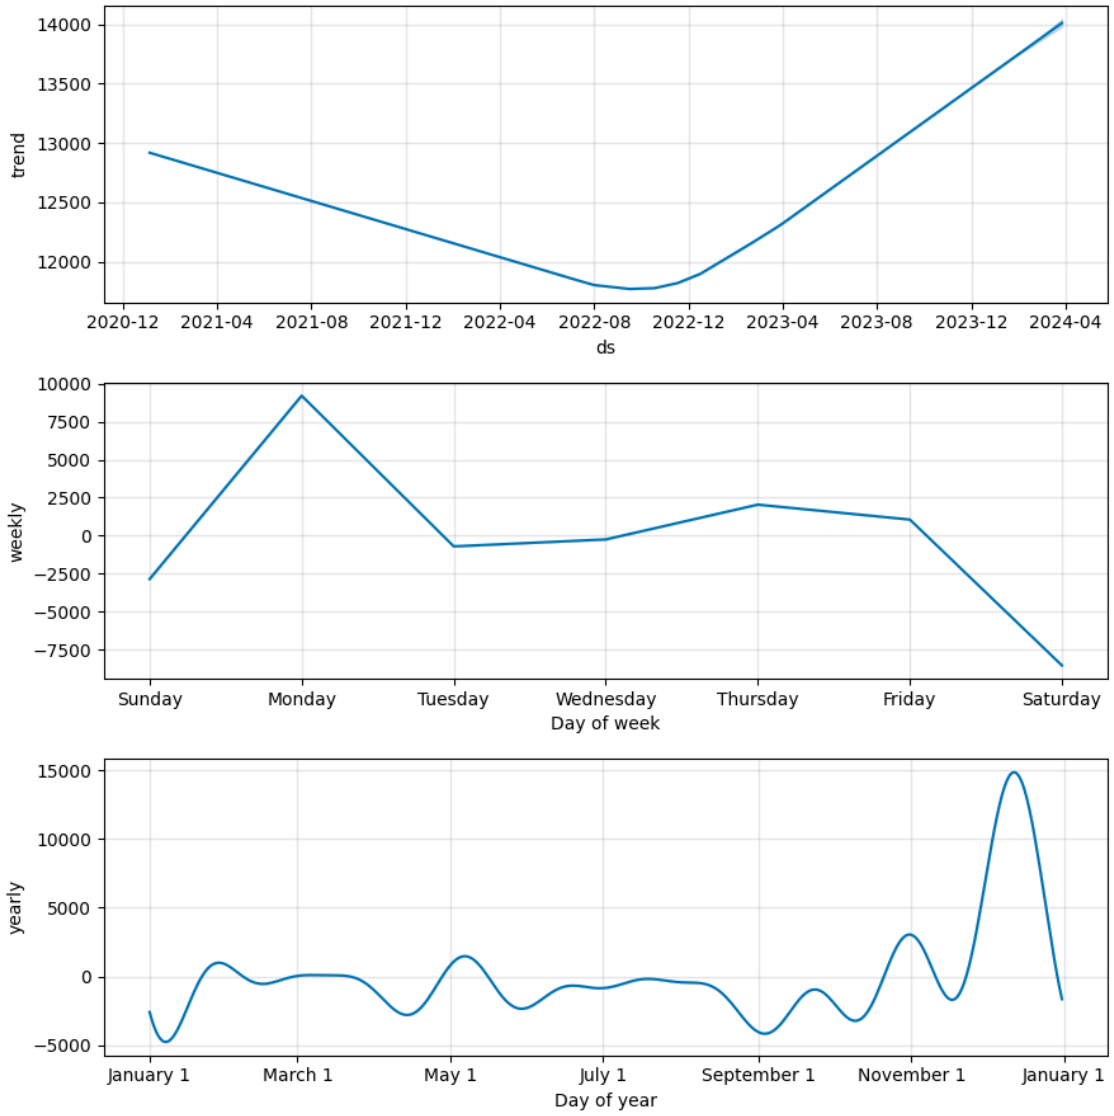

[ ]:
```
from prophet.plot import plot_plotly, plot_components_plotly

plot_plotly(m, forecast)
```

[ ]:
```
plot_components_plotly(m, forecast)
```

```
/Users/jorgebarquero/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-
packages/plotly/basedatatypes.py:2314: DeprecationWarning:

The append_trace method is deprecated and will be removed in a future version.
Please use the add_trace method with the row and col parameters.
```

```
/Users/jorgebarquero/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-
packages/plotly/basedatatypes.py:2314: DeprecationWarning:

The append_trace method is deprecated and will be removed in a future version.
Please use the add_trace method with the row and col parameters.


/Users/jorgebarquero/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-
packages/plotly/basedatatypes.py:2314: DeprecationWarning:

The append_trace method is deprecated and will be removed in a future version.
Please use the add_trace method with the row and col parameters.


/Users/jorgebarquero/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-
packages/plotly/basedatatypes.py:2314: DeprecationWarning:

The append_trace method is deprecated and will be removed in a future version.
Please use the add_trace method with the row and col parameters.


/Users/jorgebarquero/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-
packages/plotly/basedatatypes.py:2314: DeprecationWarning:

The append_trace method is deprecated and will be removed in a future version.
Please use the add_trace method with the row and col parameters.
```

[ ]:

```

```

8 Evaluación

8.1 Evaluación del algoritmo de recomendación

8.2 Evaluación de análisis de series temporales

[ ]:

```
# TRATANDO de probar el modelo
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error
import numpy as np

# Split the data into training and testing sets
X_train, X_test, y_train, y_test = train_test_split(df_prophet['ds'],␣
 ↪df_prophet['y'], test_size=0.2, random_state=0)

# Train the Prophet model
m = Prophet()
```

```
m.fit(pd.DataFrame({'ds': X_train, 'y': y_train}))

# Generate predictions for the testing data
future = pd.DataFrame({'ds': X_test})
forecast = m.predict(future)

# Calculate evaluation metrics
mse = mean_squared_error(y_test, forecast['yhat'])
rmse = np.sqrt(mse)
mae = np.mean(np.abs(y_test - forecast['yhat']))

print("Root Mean Squared Error (RMSE):", rmse)
print("Mean Absolute Error (MAE):", mae)
```

```
19:53:28 - cmdstanpy - INFO - Chain [1] start processing
19:53:28 - cmdstanpy - INFO - Chain [1] done processing
```

```
Root Mean Squared Error (RMSE): 10316.38561566022
Mean Absolute Error (MAE): 8536.758449511086
```

9 Deployment

[ ]:

[ ]: