

crisp-dm-couriers

July 6, 2024

1 Trabajo Final de Máster

Máster en Data Science For Business

Sustentantes:

- Maria Jesús Quirós
- Jorge Luis Barquero Villagra

Tutor: Ramón Alberto Carrasco

2 CRISP-DM

Requisitos previos

Para ejecutar el siguiente notebook se debe tener un ambiente de Python con las siguientes librerías instaladas.

Versión de Python 3.8.xx

- mysql-connector-python 8.4.0
- plotly 5.9.0
- mlxtend 0.23.1
- networkx 3.1
- fbprophet 1.1.5
- openpyxl 3.0.10
- nbformat 5.9.2
- kaleido 0.2.1

Instalación de paquetes

```
[ ]: # %pip install mysql-connector-python
      # %pip install plotly
      # %pip install mlxtend
      # %pip install networkx
      # %pip install fbprophet
      # %pip install openpyxl
      # %pip install nbformat
      # %pip install -U kaleido
```

Imports

```
[ ]: # Imports para ejecución del notebook
import pandas as pd
import os as os
import matplotlib.pyplot as plt
import plotly.express as px
import numpy as np
import sqlite3
import plotly.io as pio
from mlxtend.frequent_patterns import association_rules
from mlxtend.frequent_patterns import apriori
from prophet import Prophet
from IPython.display import Image
from prophet.plot import plot_plotly, plot_components_plotly
import networkx as nx
import plotly.graph_objects as go
from sklearn.metrics import mean_squared_error
import pickle
```

Variables globales

```
[ ]: # Variable global para administrar el directorio actual
parent_dir = os.path.dirname(os.getcwd())

# Configuración para los renders de plotly
pio.renderers.default = 'notebook'

# Ubicación de base de datos
database_name = '/data/database/tfm_couriers.db'

# Exportar a PDF
exportar_pdf = True

# Registrar en base de datos
salvar_en_bd = False
```

Funciones reutilizables

```
[ ]: # Funciones reutilizables
def SalvarEnBD(table_name, data):
    if salvar_en_bd:
        conn = sqlite3.connect(parent_dir + database_name)
        # Convierte el DataFrame a una tabla SQL
        data.to_sql(table_name, conn, if_exists='replace', index=False)
```

3 Business Understanding

Un courier es una empresa o servicio especializado en la entrega rápida y eficiente de paquetes, documentos y otros tipos de envíos. A diferencia de los servicios postales tradicionales, los couriers

suelen ofrecer una mayor velocidad, seguridad y confiabilidad en la entrega de sus envíos. Suelen caracterizarse porque sus servicios incluyen:

- Rapidez: Algunas empresas couriers pueden hacer entregas en el mismo día, al día siguiente o en un plazo muy corto, dependiendo de la urgencia del envío.
- Seguimiento: Los envíos por courier generalmente pueden ser rastreados en tiempo real, proporcionando información precisa sobre el estado y la ubicación del paquete.
- Seguridad: Los couriers a menudo ofrecen un manejo más cuidadoso de los envíos, con seguros y opciones de firma al recibir el paquete.
- Flexibilidad: Ofrecen una amplia gama de servicios, desde entregas locales y nacionales hasta envíos internacionales, adaptándose a las necesidades específicas de sus clientes.
- Servicio al cliente: Proporcionan atención personalizada y soluciones específicas para problemas o necesidades de envío.

Los couriers son utilizados tanto por particulares como por empresas que necesitan enviar documentos importantes, productos comprados en línea, muestras comerciales, y otros tipos de paquetes que requieren una entrega rápida y segura.

La empresa ExpediteX es una empresa dedicada a prestación de servicios logísticos de Courier y mensajería, que cuenta con 25 años de experiencia en el mercado. Sus servicios van desde la importación de productos en la modalidad de carga y paquetería, distribución local y nacional a domicilio, hasta la asesoría para la importación y exportación, casillero internacional y asesoría de compras internacionales.

Por otro lado, SwiftShip cuenta con experiencia de 19 años en el manejo y traslado de paquetes y encomiendas, se caracterizan por trabajar directamente, sea, desde el recibimiento hasta la entrega de las mercancías es manejada por la empresa directamente (sin intermediarios).

Adicionalmente cuentan con 207 sucursales y/o puntos de recepción a nivel internacional en 50 países diferentes, entre ellos Estados Unidos, Canadá, Panamá, República Dominicana, Guatemala, Venezuela, Argentina, Brasil, Chile, Colombia, Ecuador, Perú, Uruguay, España, Italia, Portugal, Alemania y el resto de la Comunidad Europea.

Ambas empresas operan en un mercado muy competitivo, donde la eficiencia en la entrega, la cobertura geográfica y la calidad del servicio al cliente son factores clave para su éxito. Estas empresas ofrecen una variedad de servicios, que van desde la entrega de paquetes locales hasta el envío internacional, adaptándose a las necesidades de diferentes segmentos del mercado, como particulares y empresas.

La integración de tecnologías avanzadas, como el rastreo en tiempo real y la gestión automatizada de inventarios y compras juega un papel crucial en la optimización de los procesos logísticos, con lo que la incorporación de toma de decisiones basadas en datos, tiene gran importancia en las empresas de courier, pues es crucial para optimizar sus operaciones, mejorar la satisfacción del cliente y aumentar la eficiencia en el manejo de envíos.

3.1 Objetivo General

Desarrollar mediante la metodología CRISP-DM un análisis de datos sobre los procesos de importación de las empresas SwiftShip y ExpediteX de courier en Costa Rica durante el período 2021-2023, para la optimización de sus operaciones y mejora de la toma de decisiones estratégicas. Utilizando técnicas avanzadas de análisis de datos y las herramientas disponibles, se espera obtener

al menos cinco recomendaciones concretas y presentar los hallazgos en un informe detallado en el plazo de cuatro meses.

3.2 Objetivos Específicos

- Implementar un análisis de cesta (basket analysis) utilizando algoritmos de asociación para la identificación de los patrones más relevantes de compra y relaciones entre los productos adquiridos por los importadores que han utilizado los servicios de las empresas SwiftShip y ExpediteX de courier en Costa Rica. Utilizando los datos de transacciones de los últimos tres años, se espera la mejora en las estrategias de marketing y optimización del servicio. El análisis se lleva a cabo y los resultados se presentan en un informe detallado en un plazo de tres meses.
- Realizar un análisis de tendencias de las mercancías importadas utilizando técnicas de análisis de series temporales, para la identificación de patrones significativos y cambios importantes en la demanda de diferentes tipos de mercancías a lo largo del tiempo. Esto permitirá la anticipación de las necesidades logísticas y ajustes de estrategias de importación para la mejora de la eficiencia operativa. Dicho análisis se completará en un plazo de seis meses.
- Diseñar un conjunto de tres variables ingenieriles específicas para la implementación en las empresas SwiftShip y ExpediteX, para la optimización de los procesos de importación bajo la modalidad courier. Utilizando técnicas de análisis de datos y conocimientos de la industria, se espera la mejora de la eficiencia y efectividad de dichos procesos. Este diseño y la implementación de un plan piloto se completarán en un plazo de cinco meses.

3.3 Definiciones

- **Aduana:** Unidad técnico-administrativa encargada de las gestiones aduaneras y del control de las entradas, la permanencia y la salida de las mercancías objeto del comercio internacional (Art. 13 LGA).
- **Agente aduanero:** Profesional auxiliar de la función pública aduanera autorizado por la DGA para actuar, en su carácter de persona natural en la presentación habitual de servicios a terceros, en los trámites, los regímenes y las operaciones aduaneras. (Art. 33, LGA)
- **Auxiliar de la Función Pública:** Personas físicas o jurídicas, públicas o privadas, que participen habitualmente ante el Servicio Nacional de Aduanas (SNA), en nombre propio o de terceros. (Art. 28 LGA).
- **Bultos:** Unidad utilizada para contener mercancías. Puede consistir en cajas, sacas, fardos, cilindros y demás formas de presentación de las mercancías, según su naturaleza (Ministerio de Hacienda, 2021).
- **Código Sistema Arancelario Centroamericano (SAC):** El Arancel Centroamericano de Importación está constituido por el Sistema Arancelario Centroamericano (SAC) y los correspondientes Derechos Arancelarios a la Importación (DAI). El código numérico del SAC está representado por diez dígitos que identifican: los dos primeros, al capítulo; los dos siguientes, a la partida; el tercer par, a la subpartida; y los cuatro últimos, a los incisos arancelarios. La identificación de las mercancías se hará siempre con los diez dígitos de dicho código numérico. (Estrategia Aduanera, s.f.)

- **Código Sistema Armonizado (SA):** El Sistema Armonizado (SA) es un código de clasificación de mercancías creado por la Organización Mundial de Aduanas (OMA) y está compuesto por 6 dígitos con aceptación en todo el mundo. Sirve para llevar un control en las mercancías de exportación e importación en cuanto a los impuestos internos, monitoreo de bienes, origen y materia constitutiva.
- **Declarante:** El importador o consignatario, en el caso de la importación de mercancías.
- **Depositorio Aduanero:** Persona física o jurídica, pública o privada, auxiliar de la función pública aduanera autorizadas mediante concesión por la DGA, que custodian y conservan temporalmente y con suspensión del pago de tributos, mercancías objeto de comercio exterior, bajo la supervisión y el control de la autoridad aduanera. (Ministerio de Hacienda, 2021).
- **Derechos Arancelarios a la Importación (DAI):** Derechos Arancelarios a la Importación que son un porcentaje estipulado por tipo de mercancías y se calcula sobre el Valor Aduanero.
- **Descripción o designación de la mercancía:** Precisa identificación de las características de ésta, sea de manera concreta, detallada, que singulariza de tal forma el objeto a clasificar que no deja duda alguna sobre su tipificación. (Quirós, 2024).
- **DUA:** Documento Único Aduanero, declaración realizada mediante transmisión electrónica de datos, mediante la cual se indica el régimen aduanero y la modalidad que deberá aplicarse a las mercancías (Ministerio de Hacienda, 2021).
- **Empresa de entrega rápida (EER):** Personas físicas o jurídicas legalmente establecidas, autorizadas y registradas ante la DGA, cuyo giro o actividad principal es la prestación de servicios de transporte internacional expreso a terceros, de correspondencia, documentos y envíos de mercancías bajo la modalidad de entrega rápida. (Ministerio de Hacienda, 2021).
- **Envíos de entrega rápida:** Documentos y mercancías transportadas bajo sistemas de entrega rápida o courier, consignadas a terceros. (Ministerio de Hacienda, 2021).
- **Factura Comercial:** Documento expedido conforme a los usos y las costumbres comerciales, justificativo de un contrato de compraventa de mercancías o servicios extendido por el vendedor a nombre y cargo del comprador.
- **Fecha:** Fecha en que fue aceptado el DUA por el Sistema de Tecnología de Información para el Control Aduanero (TICA) de Costa Rica.
- **Flete:** Monto de flete desde el origen, o sea desde el momento en que se elabora el conocimiento de embarque original y se inicia el servicio de transporte hasta el puerto o lugar de importación. (Ministerio de Hacienda, 2021).
- **Identificación (ID) Agente:** Cédula de identidad física u jurídica del Agente Aduanero.
- **Identificación (ID) Declarante:** En el caso que nos ataque, el número de identificación de la empresa declarante ante el Ministerio de Hacienda.
- **Identificación (ID) Localización:** Número de identificación de la empresa donde está localizada la mercancía, en el caso de envíos de courier, suele referirse al Depositorio Aduanero o Almacén fiscal.
- **Importador:** Empresario o empresa que se dedica a comprar productos a clientes del exterior para luego venderlos en el mercado local o para consumo o uso propio.

- **Impuesto sobre el Valor Agregado (IVA):** Según el artículo 1 de la Ley 9635, el impuesto sobre el valor agregado se establece en la venta de bienes y en la prestación de servicios, independientemente del medio por el que sean prestados, realizados en el territorio en Costa Rica.
- **Impuestos Selectivo de Consumo (SC):** Impuesto establecido sobre bienes y servicios específicos, por razones que dependen de cada Estado. Entre las razones más comunes para gravar un bien específico se encuentra, por ejemplo, el carácter indemnizatorio o el desincentivador que se pretende implementar sobre o por el consumo o realización de este. Así, es que las bebidas alcohólicas, el tabaco, y la marihuana
- **Impuestos:** Los Derechos o impuestos a la importación corresponden al monto de tributos que el fisco recauda debido al ingreso de una mercancía extranjera al comercio nacional. (Ministerio de Hacienda, 2024).
- **Ítem:** Línea del DUA donde se describe e indica la cantidad de las mercancías que se presentan para ser destinadas a un régimen aduanero determinado.
- **Ley 6946:** Tarifa de Ley N°6946, de un 1% aplicable sobre el valor aduanero.
- **Localización:** véase Depositario Aduanero.
- **Medio o modo de transporte:** Nave, aeronave, vagón ferroviario, vehículo automotor, o cualquier otro medio utilizado para el transporte de personas o mercancías. (Ministerio de Hacienda, 2021)
- **Mercancía:** Objeto susceptible de ser apropiado y, por ende, importado o exportado, clasificado conforme al arancel de aduanas.
- **Modalidad:** Cada régimen aduanero contará con modalidades según detalle, por ejemplo, la importación puede ser modalidad importación definitiva, temporal, courier, entre otras.
- **Modelo:** De las mercancías que se adquieren, por ejemplo en sitios web y se trasladan a Costa Rica, bajo la modalidad de courier.
- **Nota técnica:** requisitos no arancelarios o autorizaciones preestablecidos por la institución rectora mediante leyes y decretos, que avalan el ingreso o salida de las mercancías del o al territorio nacional. (Ministerio de Hacienda, 2021)
- **País de adquisición:** País en donde se adquirido el servicio o mercancía.
- **País de origen:** País de donde, según lo establecido en el Tratado de Libre Comercio, son originarias las mercancías o servicios.
- **País de procedencia:** País de donde procede la mercancía, que no necesariamente coincide con el país de origen o de adquisición.
- **Peso bruto:** El peso bruto es el peso total de un producto más su empaque o contenedor.
- **Peso neto:** El peso neto de un producto, sea únicamente el peso del producto en sí.
- **Precio FOB:** FOB es un término comercial que pertenece a los Incoterms, corresponde a las siglas en inglés de ‘Free on board’. El Precio FOB se determina por: precio de la mercancía, el precio de embalaje y etiquetado, precio por transporte desde la planta de producción hasta el puerto de origen, el precio del seguro de la mercancía durante su traslado a puerto, gastos administrativos generados por la concesión de permisos o licencias, gastos derivados

de las autoridades aduaneras, algunos gastos bancarios resultantes de pagos y transferencias internacionales y gastos portuarios, como uso de muelle, elevadores o estiba.

- **PROCOMER:** Promotora de Comercio Exterior de Costa Rica, pago de \$3 por cada declaración aduanera transmitida electrónicamente, para la institución.
- **Proveedor:** Persona física o jurídica que suministra profesionalmente un determinado bien o servicio a otros individuos o sociedades, como forma de actividad económica y a cambio de una contra prestación.
- **Régimen:** Diferentes destinaciones a que pueden quedar sujetas las mercancías que se encuentran bajo control aduanero (Art 109. LGA)
- **Seguro:** Protección de la carga desde que sale del depósito del vendedor hasta las bodegas del comprador, o según INCOTERM.
- **Unidad de medida:** Referencia convencional que se usa para medir la magnitud física de un determinado objeto, sustancia o fenómeno.
- **Valor CIF:** Representa el precio total de la mercancía, incluyendo el coste, del seguro y el flete hasta el puerto de destino acordado.
- **Valor en Aduana:** El valor de transacción, o precio realmente pagado o por pagar por las mercancías cuando éstas se venden para su exportación al país de importación.

4 Data Understanding

4.1 Carga de archivo de datos fuente

Se inicia con una carga del conjunto de datos, ubicado en la carpeta '/data/raw/' de nuestro directorio. Para evitar problemas de ubicación, se utiliza la variable `parent_dir` que representa el directorio padre de la solución. Esto se obtuvo al inicio de este notebook.

```
[ ]: # Lectura del archivo de datos y almacenamiento en variable data
data = pd.read_excel (parent_dir + '/data/raw/data.xlsx',
    ↪sheet_name='UnifiedData')

# Se despliega los primeros registros de los datos
data.head()
```

```
[ ]:
      DUA  Item del DUA  Fecha DUA  Aduana \
0  005-2022-001495      1  2022-01-03  SANTAMARIA
1  005-2022-001495      2  2022-01-03  SANTAMARIA
2  005-2022-001495      3  2022-01-03  SANTAMARIA
3  005-2022-001495      4  2022-01-03  SANTAMARIA
4  005-2022-001495      5  2022-01-03  SANTAMARIA

      Regimen      Modalidad Importador  Proveedor \
0  IMPORTACION DEFINITIVA  ENTREGA RAPIDA  SwiftShip  No disponible
1  IMPORTACION DEFINITIVA  ENTREGA RAPIDA  SwiftShip  No disponible
2  IMPORTACION DEFINITIVA  ENTREGA RAPIDA  SwiftShip  No disponible
```

3	IMPORTACION DEFINITIVA	ENTREGA RAPIDA	SwiftShip	No disponible
4	IMPORTACION DEFINITIVA	ENTREGA RAPIDA	SwiftShip	No disponible

	Marca	Modelo	...	Total IVA USD	% Ley 6946	\
0	No disponible	No disponible	...	6.45	1	
1	No disponible	No disponible	...	92.12	1	
2	No disponible	No disponible	...	86.12	1	
3	No disponible	No disponible	...	51.21	1	
4	No disponible	No disponible	...	9.54	1	

	Total Ley 6946 USD	% DAI	Total DAI USD	COSTO por PROCOMER USD	% S.C	\
0	0.43	14	6.04		3	0
1	5.61	14	78.49		0	10
2	5.76	14	80.65		0	0
3	3.58	9	32.23		0	0
4	0.64	14	8.94		0	0

	Total SC USD	Otros impuestos USD	Total de Impuestos
0	0.00	0.11	16.03
1	63.91	0.00	240.13
2	0.00	0.00	172.53
3	0.00	0.00	87.02
4	0.00	0.00	19.12

[5 rows x 49 columns]

4.2 Lectura de catálogos

Se carga la información del catálogo hecho con base en el Sistema Armonizado (SA), es código según se indicó con anterioridad, es una clasificación de mercancías creado por la Organización Mundial de Aduanas (OMA) y está compuesto por 6 dígitos (Subpartidas) con aceptación en casi todo el mundo.

Para facilitar la interpretación, se utiliza la codificación a nivel de partida (4 dígitos) sin que esto afecte la codificación original de la OMA.

```
[ ]: # Variable para administrar los datos de los catálogos
data_catálogo = pd.read_excel(parent_dir + '/data/raw/catalogo.xlsx',
                               sheet_name='Catálogo')

# Despliegue de primeras filas del conjunto de datos
data_catálogo.head()
```

```
[ ]: Código Sistema Armonizado \
0      9504
1      8516
2      3926
3      9506
```


	Descripción			
0	VIDEOCONSOLAS	Y	MÁQUINAS	...
1	CALENTADORES	ELÉCTRICOS	DE AGUA	DE CAL...
2	LAS DEMÁS	MANUFACTURAS	DE PLÁSTICO	Y...
3	ARTÍCULOS	Y MATERIAL	PARA CULTURA FÍSI...	
4	TRICICLOS,	PATINETES,	COCHES DE PEDAL	Y JUGUET...

4.3 Descripción de valores en columnas de datos

Hacer una descripción de valores en columnas de datos en el proceso de data understanding permite comprender el contenido y la estructura de los datos, identificar problemas de calidad, y detectar patrones y tendencias preliminares.

Este análisis inicial permite validar hipótesis, preparar adecuadamente los datos para modelos y algoritmos posteriores, y asegurar una comunicación clara y documentada de los hallazgos.

1. **DUA:** Documento Único Administrativo, identificador de la operación de importación.
2. **Item del DUA:** Número de ítem en la factura.
3. **Fecha DUA:** Fecha de la operación de importación.
4. **Aduana:** Aduana por la que ingresaron los productos.
5. **Regimen:** Régimen aduanero bajo el cual se importaron los productos.
6. **Modalidad:** Modalidad de importación.
7. **Importador:** Empresa que importó los productos.
8. **Proveedor:** Proveedor de los productos importados.
9. **Marca:** Marca de los productos importados.
10. **Modelo:** Modelo de los productos importados.
11. **Factura:** Número de factura de la operación de importación.
12. **Código SAC:** Código del Sistema Armonizado de Designación y Codificación de Mercancías.
13. **Código Sistema Armonizado:** Código del Sistema Armonizado de Designación y Codificación de Mercancías.
14. **Modo transporte:** Vía por la que se transportaron los productos.
15. **País de Origen:** País de origen de los productos.
16. **País de Procedencia:** País de procedencia de los productos.
17. **País de Adquisición:** País donde se adquirieron los productos.
18. **Cantidad:** Cantidad de productos importados.
19. **Unidad de Medida:** Unidad de medida de los productos importados.
20. **Volúmen Físico:** Volumen físico de los productos importados.
21. **Cantidad de bultos:** Cantidad de bultos en los que se transportaron los productos.
22. **Valor FOB USD:** Valor FOB (Free On Board) de los productos en dólares estadounidenses.
23. **Valor FOB USD por unidad:** Valor unitario FOB de los productos en dólares estadounidenses.
24. **Costo flete USD:** Costo del flete en dólares estadounidenses.
25. **Costo seguro USD:** Costo del seguro en dólares estadounidenses.
26. **Valor CIF USD:** Valor CIF (Cost, Insurance and Freight) de los productos en dólares estadounidenses.
27. **Valor CIF USD unitario:** Valor unitario CIF de los productos en dólares estadounidenses.
28. **Valor en Aduana USD:** Valor en aduana de los productos en dólares estadounidenses.

29. **Peso neto Kg:** Peso neto de los productos en kilogramos.
30. **Peso bruto Kg:** Peso bruto de los productos en kilogramos.
31. **Peso bruto en Libras:** Peso bruto de los productos en libras.
32. **Descripción de Mercancía:** Descripción de los productos importados.
33. **ID Declarante:** Identificador del declarante.
34. **Declarante:** Nombre del declarante.
35. **ID Agente Aduanero:** Identificador del agente de aduanas.
36. **Agente aduanero:** Nombre del agente de aduanas.
37. **ID Localización:** Identificador de la localización.
38. **Localización:** Localización de la operación de importación.
39. **% IVA:** Porcentaje del Impuesto al Valor Agregado.
40. **Total IVA USD:** Valor del IVA en dólares estadounidenses.
41. **% Ley 6946:** Porcentaje de la Ley 6946.
42. **Total Ley 6946 USD:** Valor de la Ley 6946 en dólares estadounidenses.
43. **% DAI:** Porcentaje del Derecho Arancelario de Importación.
44. **Total DAI USD:** Valor del DAI en dólares estadounidenses.
45. **COSTO por PROCOMER USD:** Valor de PROCOMER en dólares estadounidenses.
46. **% S.C:** Porcentaje de S.C.
47. **Total SC USD:** Valor de S.C en dólares estadounidenses.
48. **Otros impuestos USD:** Otros impuestos en dólares estadounidenses.
49. **Total de Impuestos:** Total de impuestos de la operación de importación.

4.4 Análisis Estadístico

Ayuda a entender cómo están distribuidos los datos en términos de frecuencia, media, mediana, moda, rangos y varianza, lo cual permite identificar patrones generales en las importaciones. Al analizar las tendencias a lo largo de los años, codificación de las mercancías importadas, países de origen y procedencia, y otros atributos, se pueden identificar patrones que ayuden a tomar decisiones estratégicas.

Además, permite detectar valores atípicos o inconsistencias en los datos, lo cual es crucial para asegurar la calidad y la integridad de la información. Identificar oportunidades para optimizar los procesos de importación, reducir costos y mejorar la eficiencia operativa también se facilita con este análisis. Asegurar que todas las importaciones cumplen con las regulaciones y requisitos legales, incluyendo la correcta aplicación de impuestos y aranceles, es fundamental para el cumplimiento normativo.

Finalmente, proporciona una base sólida para la planificación y la elaboración de pronósticos futuros, basados en el análisis de datos históricos.

```
[ ]: # Métricas descriptivas de los datos
data.describe(include='all')
```

```
[ ]:
count          DUA  Item del DUA          Fecha DUA  \
unique          4176          NaN          NaN
top    005-2023-732459          NaN          NaN
freq           480          NaN          NaN
mean          NaN    63.527013  2022-06-23  05:30:13.497427712
```

min	NaN	1.000000	2021-01-04 00:00:00
25%	NaN	12.000000	2021-08-05 00:00:00
50%	NaN	46.000000	2022-04-06 00:00:00
75%	NaN	100.000000	2023-05-17 00:00:00
max	NaN	480.000000	2023-12-28 00:00:00
std	NaN	60.202672	NaN

	Aduana	Regimen	Modalidad	Importador	\
count	178434	178434	178434	178434	
unique	1	1	2	2	
top	SANTAMARIA	IMPORTACION DEFINITIVA	ENTREGA RAPIDA	ExpediteX	
freq	178434	178434	178357	143547	
mean	NaN	NaN	NaN	NaN	
min	NaN	NaN	NaN	NaN	
25%	NaN	NaN	NaN	NaN	
50%	NaN	NaN	NaN	NaN	
75%	NaN	NaN	NaN	NaN	
max	NaN	NaN	NaN	NaN	
std	NaN	NaN	NaN	NaN	

	Proveedor	Marca	Modelo	...	Total IVA USD	\
count	178434	178434	178434	...	178434.000000	
unique	12	16	33	...	NaN	
top	No disponible	No disponible	No disponible	...	NaN	
freq	178393	178357	178357	...	NaN	
mean	NaN	NaN	NaN	...	6.062704	
min	NaN	NaN	NaN	...	0.000000	
25%	NaN	NaN	NaN	...	0.250000	
50%	NaN	NaN	NaN	...	2.230000	
75%	NaN	NaN	NaN	...	5.790000	
max	NaN	NaN	NaN	...	190.890000	
std	NaN	NaN	NaN	...	12.400669	

	% Ley 6946	Total Ley 6946 USD	% DAI	Total DAI USD	\
count	178434.0	178434.000000	178434.0	178434.000000	
unique	8.0	NaN	11.0	NaN	
top	1.0	NaN	14.0	NaN	
freq	93314.0	NaN	56616.0	NaN	
mean	NaN	0.376309	NaN	3.501689	
min	NaN	0.000000	NaN	0.000000	
25%	NaN	0.000000	NaN	0.000000	
50%	NaN	0.140000	NaN	0.940000	
75%	NaN	0.360000	NaN	3.320000	
max	NaN	11.530000	NaN	161.370000	
std	NaN	0.797761	NaN	8.447561	

COSTO por PROCOMER USD	% S.C	Total SC USD	Otros impuestos USD	\
------------------------	-------	--------------	---------------------	---

count	178434.000000	178434.0	178434.000000	178434.000000
unique	NaN	16.0	NaN	NaN
top	NaN	0.0	NaN	NaN
freq	NaN	96091.0	NaN	NaN
mean	0.066882	NaN	0.812547	0.003029
min	0.000000	NaN	0.000000	0.000000
25%	0.000000	NaN	0.000000	0.000000
50%	0.000000	NaN	0.000000	0.000000
75%	0.000000	NaN	0.000000	0.000000
max	3.000000	NaN	242.510000	12.000000
std	0.442915	NaN	5.652555	0.065990

Total de Impuestos	
count	178434.000000
unique	NaN
top	NaN
freq	NaN
mean	10.82316
min	0.000000
25%	0.59000
50%	3.94000
75%	10.43000
max	476.31000
std	23.05286

[11 rows x 49 columns]

4.5 Verificación de valores nulos

Este proceso implica identificar y manejar cualquier dato faltante en las columnas del dataset. Los valores nulos pueden distorsionar los resultados del análisis y los modelos predictivos, por lo que es fundamental tratarlos adecuadamente.

Para efectos de este estudio, no existen valores nulos en el conjunto de datos por lo que no es necesario darles tratamiento.

```
[ ]: # Revisión de valores faltantes
data.isnull().sum()
```

```
[ ]: DUA                                0
      Item del DUA                      0
      Fecha DUA                        0
      Aduana                           0
      Regimen                          0
      Modalidad                        0
      Importador                       0
      Proveedor                        0
      Marca                           0
```

Modelo	0
Factura	0
Código SAC	0
Código Sistema Armonizado	0
Modo transporte	0
País de Origen	0
Pais de Procedencia	0
Pais de Adquisición	0
Cantidad	0
Unidad de Medida	0
Volúmen Físico	0
Cantidad de bultos	0
Valor FOB USD	0
Valor FOB USD por unidad	0
Costo flete USD	0
Costo seguro USD	0
Valor CIF USD	0
Valor CIF USD unitario	0
Valor en Aduana USD	0
Peso neto Kg	0
Peso bruto Kg	0
Peso bruto en Libras	0
Descripción de Mercancía	0
ID Declarante	0
Declarante	0
ID Agente Aduanero	0
Agente aduanero	0
ID Localización	0
Localización	0
% IVA	0
Total IVA USD	0
% Ley 6946	0
Total Ley 6946 USD	0
% DAI	0
Total DAI USD	0
COSTO por PROCOMER USD	0
% S.C	0
Total SC USD	0
Otros impuestos USD	0
Total de Impuestos	0
dtype: int64	

4.6 Histogramas

Los histogramas representados permiten visualizar la distribución de los datos, identificando patrones y tendencias temporales, tipos de productos más importados y rangos de valores comunes. Facilitan la detección de outliers y variaciones en costos y pesos, ayudando a analizar la eficiencia logística y el impacto económico de las importaciones. Esta representación visual es esencial para

optimizar procesos y tomar decisiones estratégicas informadas.

Se seleccionan las siguientes variables al considerarse las más relevantes para los objetivos planteados para este estudio:


- Fecha DUA
- Código Sistema Armonizado
- Valor FOB USD
- Costo Flete USD
- Costo Seguro USD
- Valor CIF USD
- Peso bruto en libras

```
[ ]: # Lista de columnas específicas para las cuales quieres generar histogramas
columnas_especificas = ['Fecha DUA',
                        'Código Sistema Armonizado',
                        'Valor FOB USD',
                        'Costo flete USD',
                        'Costo seguro USD',
                        'Valor CIF USD', 'Peso bruto en Libras']


# Crea histogramas para las columnas especificadas
for columna in columnas_especificas:
    fig = px.histogram(data, x=columna, title=f"Histograma de {columna}")

    if (exportar_pdf == False):
        # Para generación de página web
        fig.show()
    else:
        # Para exportar en pdf
        image_bytes = pio.to_image(fig, format='png')
        display(Image(image_bytes))
```


Histograma de Fecha DUA



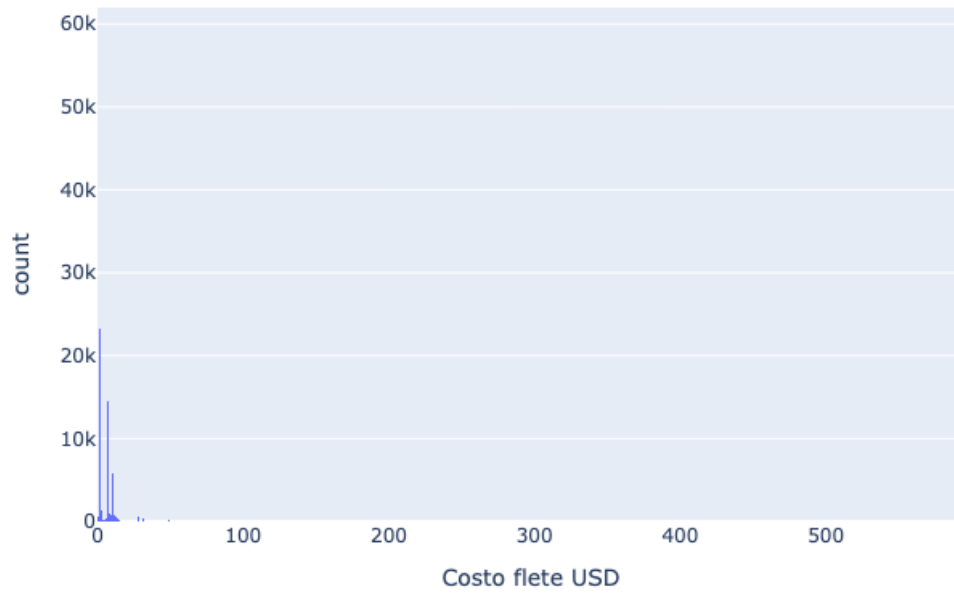
Histograma de Código Sistema Armonizado




Histograma de Valor FOB USD



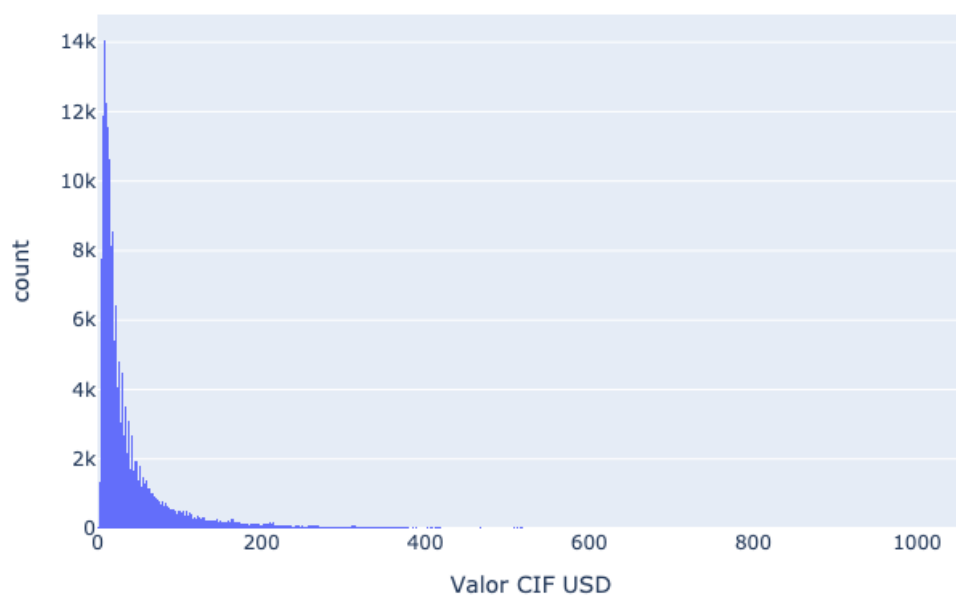
Histograma de Costo flete USD



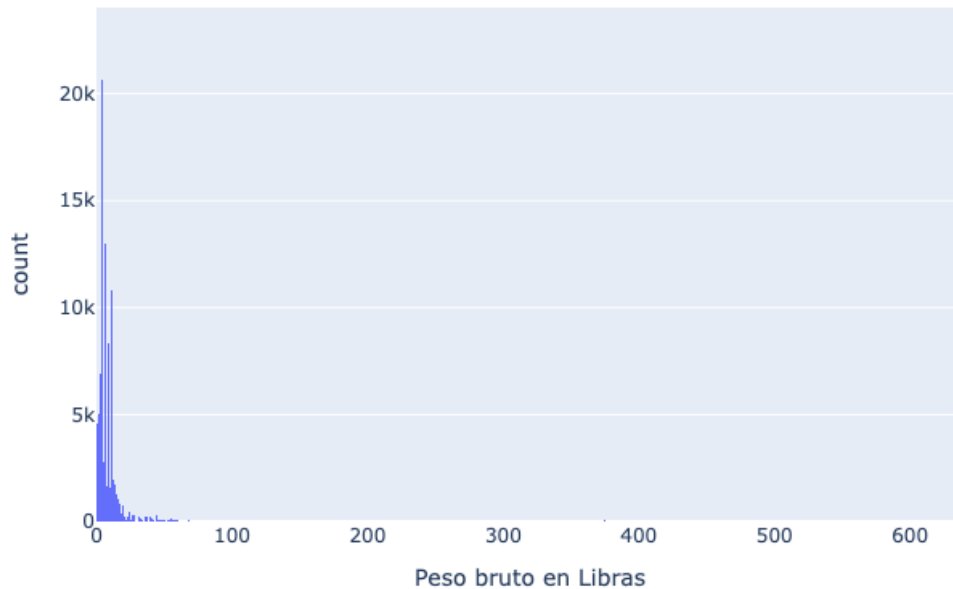
Histograma de Costo seguro USD



Histograma de Valor CIF USD



Histograma de Peso bruto en Libras



4.7 Comparativa de cantidades importadas por año

Con este gráfico se identifica tendencias en la actividad de importación, facilitando la comparación del desempeño entre ambas empresas.

Como observación, se muestra la disminución de las importaciones tramitadas durante el año 2022 por ambas empresas.

```
[ ]: data['Año'] = data['DUA'].str[4:8]
      # Mover la columna Año a la primera posición
      año = data.pop('Año')
      data.insert(0, 'Año', año)
      data['Año'] = pd.to_datetime(data['Año'])

      # Format the 'Año' column to only show the year part
      data['Año'] = data['Año'].dt.strftime('%Y')

      def create_pivot_table(data):
          pivot_df = data.pivot_table(index='Año', columns='Importador',
          ↪ values='Cantidad', aggfunc='sum').reset_index()
          plot_pivot_table(pivot_df)
```

```
def plot_pivot_table(pivot_df):


    # Preparar los datos para Plotly
    pivot_df_long = pivot_df.melt(id_vars='Año', var_name='Importador',
    ↪value_name='Cantidad')

    # Crear el gráfico de barras con Plotly
    fig = px.bar(pivot_df_long, x='Año', y='Cantidad', color='Importador',
    ↪title='Cantidades Importadas por Empresa por Año',
    labels={'Cantidad': 'Cantidad Importada', 'Año': 'Año'},
    ↪barmode='stack')

    # Mostrar el gráfico
    if (exportar_pdf == False):
        # Para generación de página web
        fig.show()
    else:
        # Para exportar en pdf
        image_bytes = pio.to_image(fig, format='png')
        display(Image(image_bytes))

create_pivot_table(data)
```

Cantidades Importadas por Empresa por Año




4.8 Top 20 DUAs por Valor CIF USD

Este código permite visualizar las 20 principales operaciones de importación (DUAs) en términos del Valor CIF (Cost, Insurance y Freight).

Al visualizar estos datos, se puede identificar cuáles son las operaciones de importación más valiosas.

```
[ ]: def plot_top_20_duas(data):  
    """  
    Grafica las 20 principales DUAs por Valor CIF USD utilizando plotly.express.  
  
    Parámetros:  
    - data (pandas.DataFrame): El DataFrame de entrada que contiene los datos.  
    """  
    # Obtener las 20 principales DUAs por cantidad  
    top_20_duas = data['DUA'].value_counts().head(20).index  
  
    # Filtrar los datos para incluir solo las DUAs seleccionadas  
    filtered_data = data[data['DUA'].isin(top_20_duas)]  
  
    # Agrupar los datos por DUA y sumar los valores de Valor FOB USD  
    aggregated_data = filtered_data.groupby('DUA')['Valor CIF USD'].sum().  
    ↪reset_index()  
  
    # Ordenar los datos por Valor FOB USD de forma descendente  
    aggregated_data = aggregated_data.sort_values(by='Valor CIF USD',  
    ↪ascending=False)  
  
    # Crear el gráfico de barras utilizando plotly express  
    fig = px.bar(aggregated_data, x='DUA', y='Valor CIF USD',  
                 labels={'DUA': 'DUA', 'Valor CIF USD': 'Valor CIF USD'},  
                 title='Top 20 DUAs por Valor CIF USD')  
    fig.update_layout(xaxis_tickangle=-90)  
  
    # Mostrar el gráfico  
    if not exportar_pdf:  
        # Para generación de página web  
        fig.show()  
    else:  
        # Para exportar en pdf  
        image_bytes = pio.to_image(fig, format='png')  
        display(Image(image_bytes))  
  
plot_top_20_duas(data)
```

Top 20 DUAs por Valor CIF USD



4.9 Dispersión de datos

Este gráfico muestra la relación entre dos variables y cómo se distribuyen los datos en el espacio bidimensional, ayudando a identificar patrones, tendencias y posibles outliers. En el caso se visualiza la relación entre el valor CIF de las mercancías y su peso neto, esto con el fin de observar el comportamiento de los costos de manejo para los importadores, en relación con el peso y valor CIF de las mercancías.

Los valores límites corresponden a mercancías que se destacan por su alto valor CIF, sin embargo no se identifican dentro del conjunto de datos ningún valor inusual que pudiese afectar la integridad de los modelos a desarrollar.

```
[ ]: def create_scatter_plot(data, exportar_pdf=False):
    """
    Crea un gráfico de dispersión con diferentes colores basado en el
    ↪ importador y muestra información adicional al pasar el cursor sobre
    ↪ 'Descripción de Mercancía'.

    Parámetros:
    - data: DataFrame que contiene los datos a graficar.
    - exportar_pdf: Booleano que indica si se exportará el gráfico como PDF o
    ↪ se mostrará en una página web. El valor predeterminado es False.
```

```

"""

# Crea el gráfico de dispersión con diferentes colores basado en el
↳ importador y muestra información adicional al pasar el cursor sobre
↳ 'Descripción de Mercancía'

fig = px.scatter(data, x='Peso bruto en Libras', y='Valor CIF USD',
↳ color='Importador',
                    title='Valor CIF USD vs. Peso bruto en Libras',
                    hover_data={'Descripción de Mercancía': True})

# Muestra el gráfico
if not exportar_pdf:
    # Para generación de página web
    fig.show()
else:
    # Para exportar como PDF
    image_bytes = pio.to_image(fig, format='png')
    display(Image(image_bytes))

create_scatter_plot(data)

```

5 Data Preparation

5.1 Ingeniería de variables

Se agregan dos variables al conjunto de datos para obtener información adicional durante el análisis

- Proporción de impuestos sobre el valor FOB: Incluir como ayuda esto al análisis
- Proporción de impuestos sobre el valor aduanero

```

[ ]: data['Proporción de impuestos sobre el valor FOB'] = (data['Total de
↳ Impuestos'] * data["Valor FOB USD"]) / 100
data['Proporción de los impuestos sobre el valor aduanero'] = (data['Total de
↳ Impuestos'] * data["Valor en Aduana USD"]) / 100

```

5.2 Unificación de datos

Se unifican ambas fuentes de datos en un solo archivo para darle tratamiento durante este proyecto.

Para realizar esto, se realiza un inner join entre ambos conjuntos de datos, y de esta manera poder contar con las descripciones para todos los items del dataset

```

[ ]: data = data.merge(data_catalogo, left_on='Código Sistema Armonizado',
↳ right_on='Código Sistema Armonizado')
data.head()

```

```

[ ]:   Año          DUA  Item del DUA  Fecha DUA      Aduana \
0  2022  005-2022-001495          1  2022-01-03  SANTAMARIA

```

1	2022	005-2022-001500	11	2022-01-03	SANTAMARIA
2	2022	005-2022-001501	8	2022-01-03	SANTAMARIA
3	2022	005-2022-040801	8	2022-01-24	SANTAMARIA
4	2022	005-2022-040801	9	2022-01-24	SANTAMARIA

	Regimen	Modalidad	Importador	Proveedor	\
0	IMPORTACION DEFINITIVA	ENTREGA RAPIDA	SwiftShip	No disponible	
1	IMPORTACION DEFINITIVA	ENTREGA RAPIDA	SwiftShip	No disponible	
2	IMPORTACION DEFINITIVA	ENTREGA RAPIDA	SwiftShip	No disponible	
3	IMPORTACION DEFINITIVA	ENTREGA RAPIDA	SwiftShip	No disponible	
4	IMPORTACION DEFINITIVA	ENTREGA RAPIDA	SwiftShip	No disponible	

	Marca	...	% DAI	Total DAI USD	COSTO por PROCOMER USD	% S.C	\
0	No disponible	...	14	6.04	3	0	
1	No disponible	...	14	120.60	0	0	
2	No disponible	...	14	57.90	0	0	
3	No disponible	...	14	9.98	0	0	
4	No disponible	...	14	11.39	0	0	

	Total SC USD	Otros impuestos USD	Total de Impuestos	\
0	0.0	0.11	16.03	
1	0.0	0.00	257.99	
2	0.0	0.00	123.87	
3	0.0	0.00	21.35	
4	0.0	0.00	24.37	

	Proporción de impuestos sobre el valor FOB	\
0	5.289900	
1	2176.610032	
2	495.467613	
3	12.807865	
4	17.059000	

	Proporción de los impuestos sobre el valor aduanero	\
0	6.918548	
1	2222.377458	
2	512.301546	
3	15.220415	
4	19.834743	

			Descripción	
0	VIDEOCONSOLAS	Y	MÁQUINAS	...
1	VIDEOCONSOLAS	Y	MÁQUINAS	...
2	VIDEOCONSOLAS	Y	MÁQUINAS	...
3	VIDEOCONSOLAS	Y	MÁQUINAS	...
4	VIDEOCONSOLAS	Y	MÁQUINAS	...

[5 rows x 53 columns]

5.3 Almacenamiento en base de datos

Se almacena el conjunto de datos ya procesado en un motor de base de datos SQLite.

```
[ ]: # Connect to the SQLite database
SalvarEnBD('FactsDatosCouriers', data)
```

6 Modeling

6.1 Basket Analysis utilizando el algoritmo Apriori

El algoritmo Apriori es una técnica fundamental en la minería de datos para la extracción de conjuntos de ítems frecuentes, lo que sirve como base para generar reglas de asociación.

6.1.1 Paso 1: Preparación de los datos

En el primer paso del Basket Analysis, se preparan los datos para el análisis. Los datos deben estar en un formato específico para que el algoritmo Apriori pueda procesarlos. Este formato se conoce como “one-hot encoding”.

En “one-hot encoding”, cada fila de los datos representa una transacción (en nuestro caso, identificada por la columna ‘DUA’) y cada columna representa un artículo (identificado por la columna ‘Código Sistema Armonizado’). Si un artículo específico está presente en una transacción, el valor en la celda correspondiente es 1, y si no está presente, el valor es 0.

Esto permite tener una representación binaria de nuestras transacciones, que es el formato requerido para el algoritmo Apriori.

```
[ ]: def codificar_unidades(x):
    """
    Función para codificar las unidades en base a una condición dada.

    Parámetros:
    x (int): El valor a codificar.

    Retorna:
    int: El valor codificado.
    """
    if x <= 0:
        return 0
    if x >= 1:
        return 1

basket = (data
          .groupby(['DUA', 'Código Sistema Armonizado'])['Código Sistema_
↪Armonizado']          # Agrupación
          .count().unstack().reset_index().fillna(0)
```

```

        .set_index('DUA'))
        # Establecer el index

# One hot encoding
conjuntos_cesta = basket.applymap(codificar_unidades)
conjuntos_cesta.head()

```

```

[ ]: Código Sistema Armonizado  2508  2513  2526  3006  3402  3405  3406  3407  \
DUA
005-2021-000324                0     0     0     0     0     0     0     0
005-2021-000341                0     0     0     0     0     0     0     0
005-2021-002548                0     0     0     0     0     0     0     0
005-2021-002659                0     0     0     0     0     0     0     0
005-2021-002660                0     0     0     0     0     0     0     0

Código Sistema Armonizado  3506  3701  ...  9613  9614  9615  9616  9617  \
DUA
005-2021-000324                0     0  ...     0     0     0     0     1
005-2021-000341                0     0  ...     0     0     0     0     0
005-2021-002548                0     0  ...     0     0     0     0     0
005-2021-002659                0     0  ...     0     0     0     0     0
005-2021-002660                0     0  ...     0     0     0     0     0

Código Sistema Armonizado  9618  9619  9620  9701  9706
DUA
005-2021-000324                0     0     1     0     0
005-2021-000341                0     0     1     0     0
005-2021-002548                0     0     0     0     0
005-2021-002659                0     0     0     0     0
005-2021-002660                0     0     0     0     0

[5 rows x 456 columns]

```

6.1.2 Paso 2: Generación de conjuntos de artículos frecuentes

El siguiente paso en el Basket Analysis es generar conjuntos de artículos frecuentes. Estos son conjuntos de artículos que aparecen juntos en las transacciones con más frecuencia que un umbral especificado. Para hacer esto, utilizamos la función `apriori` de la biblioteca `mlxtend`.

La función `apriori` toma dos argumentos principales: el `DataFrame` que contiene nuestros datos y un valor mínimo de soporte. El soporte es una medida de cuán frecuentemente aparece un conjunto de artículos en las transacciones. Al especificar un valor mínimo de soporte, le decimos a la función `apriori` que sólo queremos los conjuntos de artículos que aparecen en al menos ese porcentaje de las transacciones.

Para efectos de este estudio, se define el valor mínimo de soporte en 0.20

```
[ ]: # Construimos los conjuntos de artículos frecuentes
conjuntos_cesta_bool = conjuntos_cesta.astype(bool)

# Generamos los conjuntos de artículos frecuentes
conjuntos_frecuentes = apriori(conjuntos_cesta_bool, min_support=0.20,
    ↪use_colnames=True)

# Mostramos los primeros conjuntos de artículos frecuentes
conjuntos_frecuentes.head()
```

```
[ ]:      support itemsets
0  0.217672   (3923)
1  0.297653   (3924)
2  0.511734   (3926)
3  0.210010   (4016)
4  0.534962   (4202)
```

6.1.3 Paso 3: Generación de las reglas

En este paso, generamos las reglas a partir de los conjuntos de ítems frecuentes. Estas reglas representan patrones en los datos donde la presencia de ciertos ítems en una transacción implica la presencia de otros ítems. Para hacer esto, utilizamos la función `association_rules` de la biblioteca `mlxtend`.

La función `association_rules` toma dos argumentos principales: el DataFrame de conjuntos de ítems frecuentes y una métrica para evaluar las reglas.

Se establece la métrica “Confidence” en un valor mínimo de 0.70

```
[ ]: # Generar las reglas
reglas = association_rules(conjuntos_frecuentes, metric="confidence",
    ↪min_threshold=0.70)

# Mostrar las primeras reglas
reglas.head()
```

```
[ ]:      antecedents consequents antecedent support consequent support support \
0      (3924)      (3926)      0.297653      0.511734  0.227969
1      (3924)      (4202)      0.297653      0.534962  0.238266
2      (3924)      (4901)      0.297653      0.358477  0.209531
3      (3924)      (6404)      0.297653      0.370450  0.209531
4      (3924)      (9503)      0.297653      0.623084  0.253113

      confidence lift leverage conviction zhangs_metric
0      0.765889  1.496655  0.075650  2.085619  0.472478
1      0.800483  1.496337  0.079033  2.330817  0.472275
2      0.703942  1.963702  0.102829  2.166883  0.698740
3      0.703942  1.900234  0.099265  2.126441  0.674523
4      0.850362  1.364762  0.067650  2.518851  0.380541
```

6.1.4 Paso 4: Análisis e interpretación de las reglas

Para realizar un análisis del conjunto de reglas, se visualizan las mismas ordenadas por el valor 'lift' de manera descendente

El 'lift' es una métrica que mide la fuerza de una regla de asociación. Un 'lift' mayor que 1 indica que la regla tiene una asociación positiva fuerte, es decir, que los elementos de la regla ocurren juntos más frecuentemente de lo que se esperaría si fueran independientes. Ordenar las reglas por 'lift' de manera descendente permite enfocarse en las asociaciones más fuertes primero.

Para facilitar la lectura se definen:

- **Antecedente:** Es el elemento o conjunto de elementos que se encuentra en la parte inicial de una regla de asociación. Representa la condición o el conjunto de condiciones que se evalúan para predecir la ocurrencia de otro elemento. En términos simples, el antecedente es lo que se tiene antes de aplicar la regla.
- **Consecuente:** Es el elemento o conjunto de elementos que se encuentra en la parte final de una regla de asociación. Representa el resultado o la conclusión que se deriva de la presencia del antecedente. El consecuente es lo que se espera que ocurra dado que se ha cumplido la condición establecida por el antecedente.
- **Antecedent Support:** El soporte del antecedente es la proporción de transacciones en el conjunto de datos que contienen los antecedentes. Indica qué tan frecuentemente aparecen los antecedentes en todas las transacciones.
- **Consequent Support:** El soporte del consecuente es la proporción de transacciones en el conjunto de datos que contienen los consecuentes. Muestra qué tan frecuentemente aparecen los consecuentes en todas las transacciones.
- **Support:** El soporte de la regla es la proporción de transacciones en el conjunto de datos que contienen tanto los antecedentes como los consecuentes. Este valor mide qué tan frecuentemente aparece la combinación completa en el conjunto de datos.
- **Confidence:** La confianza de la regla es la proporción de las transacciones con los antecedentes que también contienen los consecuentes. Mide la fiabilidad de la inferencia hecha por la regla, es decir, qué tan a menudo la regla ha sido encontrada verdadera.
- **Lift:** El lift es la razón del soporte observado de la regla sobre el soporte esperado si los antecedentes y consecuentes fueran independientes. Un lift mayor que 1 indica que los antecedentes y consecuentes aparecen juntos más frecuentemente de lo esperado, lo que sugiere una relación fuerte entre ellos.
- **Leverage:** El leverage mide la diferencia entre el soporte observado de los antecedentes y consecuentes apareciendo juntos y el soporte esperado de estos si fueran independientes. Un valor más alto indica una relación más fuerte.
- **Conviction:** La convicción es una medida de la dependencia del consecuente a los antecedentes. Un valor alto de convicción significa que es muy probable que el consecuente dependa de los antecedentes.
- **Zhang's Metric:** La métrica de Zhang proporciona una medida de la certeza de la regla, considerando tanto el soporte como la confianza. Varía entre -1 y 1, donde valores cercanos a 1 indican una regla positiva fuerte, y valores cercanos a -1 indican una regla negativa fuerte.

```
[ ]: # Ordenamos las reglas por lift en orden descendente, siguiendo consejo de D.
      ↪ Ramón
reglas_ordenadas_por_lift = reglas.sort_values('lift', ascending=False)

# Mostramos las primeras reglas
reglas_ordenadas_por_lift.head()
```

```
[ ]:      antecedents      consequents antecedent support \
825  (6404, 4901, 9503)      (6403)      0.257184
830      (6403) (6404, 4901, 9503)      0.236351
828      (6403, 9503)      (6404, 4901)      0.229646
829      (6404, 4901)      (6403, 9503)      0.266284
915  (4202, 6404, 3926)      (4901, 8471)      0.245929

      consequent support      support confidence      lift leverage conviction \
825      0.236351 0.200192      0.778399 3.293406 0.139406      3.446048
830      0.257184 0.200192      0.847011 3.293406 0.139406      4.855361
828      0.266284 0.200192      0.871741 3.273734 0.139041      5.720602
829      0.229646 0.200192      0.751799 3.273734 0.139041      3.103747
915      0.252155 0.200431      0.814995 3.232117 0.138419      4.042298

      zhangs_metric
825      0.937464
830      0.911888
828      0.901583
829      0.946603
915      0.915836
```

6.2 Análisis de series temporales

6.2.1 Paso 1: Preparación de los datos para el análisis de serie temporal

En el primer paso de nuestro análisis de serie temporal, nos enfocamos en preparar los datos para su posterior exploración y modelado. Este proceso implica agrupar los datos según fechas específicas y sumar los valores asociados para cada grupo. El objetivo es obtener una visión clara de cómo se comporta la variable de interés ('Valor CIF USD') a lo largo del tiempo.

```
[ ]: grouped_data = data.groupby('Fecha DUA')['Valor CIF USD'].sum().reset_index()
grouped_data.head()
```

```
[ ]:      Fecha DUA      Valor CIF USD
0  2021-01-04      7226.16
1  2021-01-05      16784.84
2  2021-01-06      12538.98
3  2021-01-07      6144.09
4  2021-01-08      6306.10
```

6.2.2 Paso 2: Preparación de datos para modelado con Prophet

Después de agrupar y sumar los datos en el paso anterior, el siguiente paso es preparar los datos específicamente para el modelado con la biblioteca Prophet de Facebook. Prophet espera que los nombres de las columnas de la serie temporal sean 'ds' para la fecha y 'y' para la variable que queremos predecir.

```
[ ]: # Se prepara la variable data_prophet según lo esperado por Prophet
data_prophet = grouped_data[['Fecha DUA', 'Valor CIF USD']].
    ↪rename(columns={'Fecha DUA': 'ds', 'Valor CIF USD': 'y'})
```

6.2.3 Paso 3: Entrenamiento del modelo con Prophet

Una vez que hemos preparado nuestros datos con las columnas 'ds' y 'y', el siguiente paso es entrenar el modelo de serie temporal.

```
[ ]: # Inicialización del modelo
model_prophet = Prophet()

# Entrenamiento del modelo
model_prophet.fit(data_prophet)
```

```
13:29:17 - cmdstanpy - INFO - Chain [1] start processing
```

```
13:29:17 - cmdstanpy - INFO - Chain [1] done processing
```

```
[ ]: <prophet.forecaster.Prophet at 0x32cefcd00>
```

6.2.4 Paso 4: Generación de Fechas Futuras para Predicción

Después de entrenar el modelo con los datos históricos, el siguiente paso es preparar el modelo para hacer predicciones sobre el futuro.

Esto implica crear un nuevo DataFrame que contenga las fechas futuras para las cuales queremos predecir los valores de nuestra serie temporal.

Para efectos del presente estudio se estiman **90** días.

```
[ ]: # Creación de fechas futuras (90 días)
future = model_prophet.make_future_dataframe(periods=90)

# Visualización de las fechas generadas
future.tail()
```

```
[ ]:      ds
689 2024-03-23
690 2024-03-24
691 2024-03-25
692 2024-03-26
693 2024-03-27
```

6.2.5 Paso 5: Realización de Predicciones

Una vez generadas las fechas futuras para las cuales queremos hacer predicciones, el siguiente paso es utilizar el modelo entrenado para predecir los valores de la serie temporal en esas fechas.

Esto se logra con el método `predict` de Prophet, que toma el DataFrame de fechas futuras y devuelve un nuevo DataFrame con las predicciones.

```
[ ]: # Realización de predicciones
forecast = model_prophet.predict(future)
# Acceso a resultados relevantes
forecast.tail()
```

```
[ ]:      ds      trend  yhat_lower  yhat_upper  trend_lower  \
689 2024-03-23 13992.817610 -4799.813745 16112.622485 13963.534515
690 2024-03-24 13997.503154  128.418282 21337.126320 13967.629888
691 2024-03-25 14002.188698 12159.927356 33302.104362 13971.768301
692 2024-03-26 14006.874241  1478.895978 23731.182463 13975.626411
693 2024-03-27 14011.559785  2621.642641 23904.779387 13979.782638

      trend_upper  additive_terms  additive_terms_lower  additive_terms_upper  \
689 14021.614256   -8584.285992          -8584.285992   -8584.285992
690 14027.079190   -2968.710808          -2968.710808   -2968.710808
691 14032.375481    9013.052082          9013.052082    9013.052082
692 14037.666548   -979.978888          -979.978888   -979.978888
693 14043.003108   -627.462714          -627.462714   -627.462714

      weekly  weekly_lower  weekly_upper  yearly  yearly_lower  \
689 -8523.604893 -8523.604893 -8523.604893 -60.681099 -60.681099
690 -2848.804096 -2848.804096 -2848.804096 -119.906712 -119.906712
691  9206.174545  9206.174545  9206.174545 -193.122463 -193.122463
692 -698.771842 -698.771842 -698.771842 -281.207046 -281.207046
693 -242.807462 -242.807462 -242.807462 -384.655252 -384.655252

      yearly_upper  multiplicative_terms  multiplicative_terms_lower  \
689   -60.681099              0.0              0.0
690  -119.906712              0.0              0.0
691  -193.122463              0.0              0.0
692  -281.207046              0.0              0.0
693  -384.655252              0.0              0.0

      multiplicative_terms_upper  yhat
689              0.0  5408.531618
690              0.0 11028.792346
691              0.0 23015.240779
692              0.0 13026.895353
693              0.0 13384.097071
```


6.2.6 Paso 6: Visualización de las predicciones

`model.plot(forecast)` genera un gráfico que incluye los datos históricos, las predicciones futuras y los intervalos de confianza.

En este gráfico:

- Los puntos negros representan los datos históricos.
- La línea azul muestra las predicciones futuras (`yhat`).
- Las sombras azules alrededor de la línea de predicción representan los intervalos de confianza (`yhat_lower` y `yhat_upper`).

```
[ ]: # Visualización de predicciones
fig = model_prophet.plot(forecast)
```



6.2.7 Paso 7: Descomposición de componentes de la serie temporal

Después de visualizar las predicciones generales de la serie temporal, se analizan los componentes individuales:

- Tendencia general de la serie temporal: Se puede visualizar un descenso en la información del 2022, principalmente debido a un período donde ambos couriers no reportaron información, específicamente el mes de mayo 2022.
- Estacionalidad semanal: se destaca el lunes como el día en que se presentan a despacho mercancías con mayor valor CIF durante la semana.
- Estacionalidad anual de la serie temporal: se destacan picos de consumo en noviembre y diciembre, asociado a las fechas festivas.


```
[ ]: # Descomposición de componentes de serie temporal
# Versión estática
fig = model_prophet.plot_components(forecast)
```



```
[ ]: # Descomposición de componentes de serie temporal
# Versión interactiva
plot_components_plotly(model_prophet, forecast)
```

/Users/jorgebarquero/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-packages/plotly/basedatatypes.py:2314: DeprecationWarning:

The append_trace method is deprecated and will be removed in a future version. Please use the add_trace method with the row and col parameters.

```
/Users/jorgebarquero/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-  
packages/plotly/basedatatypes.py:2314: DeprecationWarning:
```

The `append_trace` method is deprecated and will be removed in a future version.
Please use the `add_trace` method with the `row` and `col` parameters.

```
/Users/jorgebarquero/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-  
packages/plotly/basedatatypes.py:2314: DeprecationWarning:
```

The `append_trace` method is deprecated and will be removed in a future version.
Please use the `add_trace` method with the `row` and `col` parameters.

```
/Users/jorgebarquero/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-  
packages/plotly/basedatatypes.py:2314: DeprecationWarning:
```

The `append_trace` method is deprecated and will be removed in a future version.
Please use the `add_trace` method with the `row` and `col` parameters.

```
/Users/jorgebarquero/anaconda3/envs/Enae_SeriesTemporales/lib/python3.8/site-  
packages/plotly/basedatatypes.py:2314: DeprecationWarning:
```

The `append_trace` method is deprecated and will be removed in a future version.
Please use the `add_trace` method with the `row` and `col` parameters.

6.2.8 Paso 8: Visualización interactiva de datos

Después de descomponer la serie temporal, se realiza una visualización interactiva a fin de explorar más a fondo las predicciones y componentes del modelo Prophet.

Esto permite una inspección detallada, facilitando la identificación de patrones específicos, anomalías o puntos de interés en los datos.

```
[ ]: # Visualización interactiva de datos  
plot_plotly(model_prophet, forecast)
```

7 Evaluation

7.1 Evaluación del algoritmo de recomendación

7.1.1 Reglas de Asociación: Soporte vs. Confianza

Este gráfico de dispersión ilustra la relación entre el soporte y la confianza de las reglas de asociación derivadas del análisis de datos.

Permite comprender cómo diferentes productos importados se relacionan entre sí.

- **Soporte:** Refleja la frecuencia con la que aparece una combinación de productos (antecedente y consecuente) en el dataset. Un valor más alto indica que la regla es común, representado en el eje X del gráfico.
- **Confianza:** Indica la probabilidad de encontrar el consecuente dado el antecedente. Una mayor confianza sugiere una mayor verosimilitud de la regla, mostrada en el eje Y.
- **Lift (Tamaño del punto):** El tamaño de los puntos muestra el “lift” de cada regla, evaluando la fuerza de la asociación.

Este análisis permite identificar patrones de compra significativos y ajustar estrategias de importación.

```
[ ]: reglas['antecedents'] = reglas['antecedents'].apply(list)
reglas['consequents'] = reglas['consequents'].apply(list)


# Crear el gráfico de dispersión
fig = px.scatter(reglas, x="support", y="confidence", size="lift",
                 hover_data=['antecedents', 'consequents'],
                 size_max=60, title="Reglas de Asociación: Soporte vs. ↵
                 ↵Confianza")

# Actualizar los títulos de los ejes
fig.update_xaxes(title_text='Soporte')
fig.update_yaxes(title_text='Confianza')

# Ajustar la altura del gráfico
fig.update_layout(height=800) # Establecer la altura en 800 píxeles

# Mostrar el gráfico
if not exportar_pdf:
    # Para generación de página web
    fig.show()
else:
    # Para exportar como PDF
    image_bytes = pio.to_image(fig, format='png')
    display(Image(image_bytes))
```

Reglas de Asociación: Soporte vs. Confianza



7.1.2 Diagrama de red de reglas generadas

Para facilitar el proceso de entendimiento del conjunto de reglas generadas y como los distintos códigos del sistema armonizado se relacionan entre sí, se genera un diagrama de red utilizando la librería `networkx`.

Funcionamiento:

El siguiente bloque de código permite entender cómo diferentes productos, clasificados bajo el Código del Sistema Armonizado, se relacionan entre sí en términos de cómo frecuentemente se

compran juntos.

1. **Crea un espacio para los productos:** se crea un espacio virtual donde cada producto, identificado por su Código del Sistema Armonizado, tiene su lugar. Esto permite visualizar las relaciones entre ellos.
2. **Identificar Relaciones:** se analizan las reglas de asociación, que son los patrones que permiten entender cómo la compra de un producto puede influir en la compra de otro.
3. **Dibujar Conexiones:** Basándonos en estas relaciones, se dibujan líneas entre los productos que se compran juntos. La grosura de la línea indica cuán fuerte es esta relación de compra conjunta, es decir, un “lift” más alto significa una relación más fuerte.
4. **Organizar los Productos:** Los productos se organizan de manera que aquellos con relaciones más fuertes estén más cerca unos de otros. Esto permite visualizar grupos de productos que suelen ser comprados juntos, facilitando la identificación de patrones de compra.

```
[ ]: # Crear un grafo
G = nx.Graph()

# Agregar nodos y aristas desde el DataFrame de reglas
for _, row in reglas.iterrows():
    antecedents = ', '.join(str(item) for item in row['antecedents'])
    consequents = ', '.join(str(item) for item in row['consequents'])
    G.add_node(antecedents, type='antecedente')
    G.add_node(consequents, type='consecuente')
    G.add_edge(antecedents, consequents, weight=row['lift'])

# Ajustar el diseño del grafo con un valor k más grande para mayor separación
pos = nx.spring_layout(G, k=0.30) # Aumentar k para separar más los nodos

# Crear trazas de aristas
edge_x = []
edge_y = []
for edge in G.edges():
    x0, y0 = pos[edge[0]]
    x1, y1 = pos[edge[1]]
    edge_x.extend([x0, x1, None])
    edge_y.extend([y0, y1, None])

edge_trace = go.Scatter(x=edge_x, y=edge_y, line=dict(width=0.5, color='#888'),
    hoverinfo='none', mode='lines')

# Crear trazas de nodos
node_x = []
node_y = []
text = []
for node in G.nodes():
    x, y = pos[node]
```



Descripción de códigos sobresalientes

- **4202:** Baúles, maletas (valijas), maletines, incluidos los de aseo y los portadocumentos, portafolios (carteras de mano), cartapacios, fundas y estuches para gafas (anteojos), binoculares, cámaras fotográficas o cinematográficas, instrumentos musicales o armas y continentes similares; sacos de viaje, sacos (bolsas) aislantes para alimentos y bebidas, bolsas de aseo, mochilas, bolsos de mano (carteras), bolsas para la compra, billeteras, portamonedas, portamapas, petacas, pitilleras y bolsas para tabaco, bolsas para herramientas y para artículos de deporte, estuches para frascos y botellas, estuches para joyas, polveras, estuches para orfebrería y continentes similares, de cuero natural o regenerado, hojas de plástico, materia textil, fibra vulcanizada o cartón, o recubiertos totalmente o en su mayor parte con esas materias o papel.
- **4901:** libros, folletos e impresos similares, incluso en hojas sueltas.
- **9503:** Triciclos, patinetes, coches de pedal y juguetes similares con ruedas; coches y sillas de ruedas para muñecas o muñecos; muñecas o muñecos; los demás juguetes; modelos reducidos y modelos similares, para entretenimiento, incluso animados; rompecabezas de cualquier clase.

Se pueden destacar las siguiente observaciones:

Observación	Descripción
Correlación entre tipos de productos	Nótese un posible frecuencia con la que se compran maletas o bolsos de mano (4202) junto con juguetes como maletas de juguete o carros de juguete (9503). Esto podría revelar patrones de compra que indican compras conjuntas o sugerencias de productos relacionados.
Asociación entre productos complementarios.	Observar la co-ocurrencia de productos como libros (4901) con artículos específicos de la categoría 4202, como guías de viaje. Esto revela asociaciones entre productos que los consumidores tienden a comprar juntos.
Impacto de la temporada o eventos específicos.	Denotar como los libros educativos sobre juguetes (4901) pueden influir en la compra de juguetes específicos (9503) durante ciertas épocas del año, como las festividades o eventos especiales.

7.2 Evaluación de análisis de series temporales

7.2.1 Verificación de valores de predicción

Se despliegan las métricas obtenidas para la predicción de los 90 días establecidos en la serie temporal.

Para evaluar mejor la información, se definen los valores más relevantes:

- **ds**: Corresponde a la fecha de la predicción.
- **yhat**: Valor predicho para la serie temporal.
- **yhat_lower** y **yhat_upper**: Límites inferior y superior del intervalo de confianza de las predicciones.
- **trend**: Componente de tendencia de la serie temporal.
- **additive_terms**: Representa la suma de los componentes no lineales del modelo.
- **additive_terms_lower** y **additive_terms_upper**: Estos son los límites inferior y superior para el intervalo de confianza de los términos aditivos. Proporcionan una medida de la incertidumbre asociada con los componentes aditivos del modelo.

```
[ ]: forecast[['ds', 'yhat', 'yhat_lower', 'yhat_upper',
↳ 'trend', 'additive_terms', 'additive_terms_lower', 'additive_terms_upper']].
↳ tail()
```

```
[ ]:
      ds      yhat    yhat_lower    yhat_upper    trend \
689 2024-03-23  5408.531618 -4799.813745  16112.622485  13992.817610
690 2024-03-24  11028.792346   128.418282  21337.126320  13997.503154
691 2024-03-25  23015.240779  12159.927356  33302.104362  14002.188698
692 2024-03-26  13026.895353  1478.895978  23731.182463  14006.874241
693 2024-03-27  13384.097071  2621.642641  23904.779387  14011.559785

      additive_terms  additive_terms_lower  additive_terms_upper
689      -8584.285992      -8584.285992      -8584.285992
690     -2968.710808     -2968.710808     -2968.710808
691      9013.052082      9013.052082      9013.052082
692     -979.978888     -979.978888     -979.978888
693     -627.462714     -627.462714     -627.462714
```

8 Deployment

8.1 Exportación de los modelos generados

Se almacenan los datos de ambos modelos en el fichero de salida definido para el proyecto

Almacenamiento modelo de series temporales

```
[ ]: # Especifica la ruta donde deseas guardar el modelo
model_path = parent_dir + '/data/out/model_prophet.pkl'

# Guarda el modelo
with open(model_path, 'wb') as f:
    pickle.dump(model_prophet, f)

print(f'Modelo de series temporales almacenado en: {model_path}')
```

Modelo de series temporales almacenado en:

/Users/jorgebarquero/GitRepos/couriersTFM/CouriersCR/data/out/model_prophet.pkl

Almacenamiento de modelo de basket analysis


```
[ ]: rules_path = parent_dir + '/data/out/reglas.pkl'

with open(rules_path, 'wb') as f:
    pickle.dump(reglas, f)

print(f"Reglas almacenadas en: {rules_path}")
```

Reglas almacenadas en:

/Users/jorgebarquero/GitRepos/couriersTFM/CouriersCR/data/out/reglas.pkl